

Planteamiento del problema y relevancia social (datos estadísticos de El Salvador)

En El Salvador, redes sociales como X y Facebook se han convertido en espacios clave para el debate público. Sin embargo, la penetración de internet en el país (que ronda el 70% de la población para 2026) ha democratizado la opinión al mismo tiempo que ha amplificado la polarización. Ambas plataformas presentan dinámicas distintas: X se caracteriza por contenido corto, reactivo y altamente polarizado. Por su parte, Facebook fomenta comentarios más extensos y discusiones en grupos y páginas públicas.

El contenido tóxico y el discurso de odio se manifiestan de forma diferente en cada plataforma, lo que dificulta su análisis con modelos genéricos. Actualmente, no existen herramientas adaptadas al contexto salvadoreño que integren análisis multifuente (cross-platform) y consideren el lenguaje local, incluyendo modismos, sarcasmo y variaciones lingüísticas. La falta de estas herramientas limita la capacidad de monitoreo, análisis y toma de decisiones basadas en datos reales del país. Desde una perspectiva social, la normalización de la violencia digital en El Salvador afecta la salud mental de los usuarios y polariza el discurso político-social, haciendo urgente la creación de mecanismos de detección precisos.

Objetivos

Objetivo general

- ❖ Desarrollar un sistema de clasificación automática de contenido textual para detectar niveles de toxicidad y discurso de odio en publicaciones de X y Facebook sobre temas sociales en El Salvador, mediante el fine-tuning de modelos de lenguaje multilingües (mBERT y XLM-R).

Objetivos específicos

- ❖ Recolectar y construir un dataset propio que incluya tuits de X y comentarios/publicaciones públicas de Facebook.
- ❖ Etiquetar el dataset en múltiples clases de toxicidad, incluyendo: no tóxico, lenguaje ofensivo, discurso de odio y amenazas/violencia.
- ❖ Entrenar y realizar fine-tuning a los modelos mBERT y XLM-R para lograr que el modelo sea capaz de generalizar entre plataformas.
- ❖ Alcanzar una precisión en la clasificación superior al 80% utilizando la métrica F1-score macro.
- ❖ Realizar una comparativa de rendimiento entre las plataformas (X vs Facebook) y los modelos (mBERT vs XLM-R).
- ❖ Desarrollar un prototipo funcional a través de una API REST o interfaz web.

Justificación e impacto esperado

La inclusión de múltiples plataformas aporta valor al proporcionar una cobertura más realista del problema, ya que el discurso de odio no se limita a una sola red y analizar X junto con Facebook permite una visión más completa. Técnicamente, entrenar con datos diversos mejora la generalización del modelo, reduciendo el overfitting a un solo tipo de texto. Además, este proyecto explora el fine-tuning de modelos como mBERT y XLM-R en un entorno multifuente, representando un caso de uso avanzado en NLP aplicado al español regional salvadoreño.

El impacto práctico es significativo, ya que el sistema puede ser utilizado en escenarios reales de moderación, análisis social o investigación. Beneficiará directamente a investigadores sociales, universidades, analistas de datos, equipos de moderación de contenido, así como a ONGs y entidades de monitoreo digital.

Marco teórico breve (técnicas ML seleccionadas + ecuaciones clave)

El proyecto se fundamenta en el Procesamiento de Lenguaje Natural (NLP) avanzado, específicamente utilizando arquitecturas basadas en Transformers. Se emplearán modelos multilingües preentrenados:

- ❖ **mBERT (Multilingual BERT)**: Entrenado en 104 idiomas mediante Masked Language Modeling (MLM).
- ❖ **XLM-R (Cross-lingual Language Model - RoBERTa)**: Optimizado con un vocabulario más extenso y mayor volumen de datos de entrenamiento, mostrando superioridad en tareas de lenguajes de bajos recursos o dialectos.

Para adaptar estos modelos, se utiliza el Fine-tuning, ajustando los pesos de las últimas capas para la tarea específica de clasificación multiclase. Matemáticamente, la predicción de la clase de toxicidad se realiza mediante la función Softmax, que convierte los logits del modelo en probabilidades:

$$P(y = j \mid \mathbf{x}) = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}$$

Donde z es el vector de salida del modelo y K es el número total de clases (ej. no tóxico, ofensivo, odio, amenazas). Durante el entrenamiento, el modelo optimiza sus pesos minimizando la función de pérdida *Cross-Entropy* categórica:

$$L = - \sum_{c=1}^M y_{o,c} \log(p_{o,c})$$

Dado que en problemas de detección de toxicidad los datos suelen estar desbalanceados, la métrica principal para evaluar el rendimiento será el **F1-Score macro** (objetivo > 80%), el cual es la media armónica de la Precisión (P) y la Exhaustividad (R):

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R}$$

Metodología propuesta (CRISP-DM o equivalente)

Se utilizará la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), adaptada a un enfoque de transfer learning en dos etapas que elimina la dependencia de APIs restringidas y garantiza la viabilidad del proyecto:

- ❖ **Comprensión del Negocio:** Definición de las cuatro categorías de toxicidad (no tóxico, lenguaje ofensivo, discurso de odio, amenazas/violencia) adaptadas al contexto sociopolítico salvadoreño. Se establecerán guías de anotación específicas que contemplen modismos, sarcasmo y variaciones lingüísticas locales.
- ❖ **Comprensión y Adquisición de los Datos:** Se adopta un enfoque de transfer learning en dos etapas que prescinde del scraping automatizado. En la primera etapa se utilizarán datasets públicos de toxicidad en español disponibles en Hugging Face: HatEval (SemEval 2019, ~6,600 tuits etiquetados), el Spanish Hate Speech Superset (~13,000 ejemplos combinados), DETOXIS/IberBench (~3,460 filas de toxicidad) y el Multilingual Toxicity Dataset (incluye el corpus CLANDESTINO en español). En la segunda etapa se construirá un corpus salvadoreño propio de 1,000 a 2,000 ejemplos recopilados manualmente mediante captura directa (copiar/pegar) de publicaciones públicas, método éticamente válido que cumple los términos de servicio de las plataformas.
- ❖ **Preparación de los Datos:** Normalización y limpieza de ambas fuentes de datos (eliminación de duplicados, URLs, menciones y caracteres especiales). Armonización de esquemas de etiquetado entre los datasets públicos y el corpus salvadoreño. Anonimización de usuarios en el corpus manual. Aplicación de técnicas de data augmentation y ponderación de clases (class weighting) para mitigar el desbalance inherente en datos de toxicidad.
- ❖ **Modelado:** Implementación del fine-tuning en dos etapas usando la biblioteca Hugging Face Transformers con Trainer API en Python (PyTorch). Primera etapa: fine-tuning de mBERT y XLM-R sobre los datasets públicos combinados en español. Segunda etapa: fine-tuning adicional (domain adaptation) sobre el corpus salvadoreño para especializar los modelos al registro lingüístico local. Se usarán como baselines los modelos preentrenados disponibles: RoBERTuito Hate Speech (pysentimiento/robertuito-hate-speech) y XLM-R Toxicity Classifier (textdetox/xlmr-large-toxicity-classifier).
- ❖ **Evaluación:** Comparativa de rendimiento entre los modelos fine-tuned (mBERT vs XLM-R) y los baselines preentrenados, usando F1-score macro como métrica principal (objetivo superior al 80%). Se analizará el impacto del domain adaptation salvadoreño mediante ablation study: modelo entrenado solo con datos públicos versus modelo con fine-tuning local adicional. También se evaluará la generalización cross-plataforma (X vs Facebook) dentro del corpus manual

❖ **Despliegue:** Desarrollo de un prototipo funcional con FastAPI como backend (endpoint POST que recibe texto y retorna la clasificación con probabilidades por clase) y una interfaz visual

Cronograma detallado (Gantt) y distribución de tareas

Nota: Se asume un ciclo de desarrollo estándar de 6 meses (abril a septiembre de 2026), ajustado a la fecha de inicio del 06 de abril.

Mes	Fase (CRISP-DM)	Tareas Principales
Mes 1	Comprensión	Definición teórica, gestión de accesos a APIs (X y Facebook Graph API).
Mes 2	Datos (Recolección)	<i>Scraping</i> ético, recolección de tuits y posts/comentarios públicos.
Mes 3	Datos (Preparación)	Limpieza de ruido, anonimización y etiquetado multiclase del dataset.
Mes 4	Modelado	<i>Fine-tuning</i> de mBERT y XLM-R con el dataset salvadoreño.
Mes 5	Evaluación	Análisis de métricas (F1-score), comparativa entre plataformas y resolución de sesgos.
Mes 6	Despliegue	Desarrollo de API REST/Web, redacción del documento final y defensa.

Mes	Tipo de Incidencia	Clave de Incidencia	Tareas Correspondientes

Abril	Epic	TFM-1	Iniciación y Planificación
Abril	Epic	TFM-2	Plan de Proyecto y Taxonomía Aprobada
Abril	Historia	TFM-18	Reunión inicial con asesores y definición de alcance
Abril	Historia	TFM-19	Definición de Taxonomía (Odio, Toxicidad, Neutro)
Abril	Historia	TFM-20	Elaboración de Guía de Etiquetado y métricas Kappa
Abril	Historia	TFM-21	Configuración de entorno (Hugging Face / Colab GPU)
Abril	Historia	TFM-22	Extracción de datos (X API y Scraping Facebook)
Mayo	Historia	TFM-23	Limpieza, anonimización y pre-procesamiento
Mayo	Historia	TFM-24	Etiquetado Manual (Dataset Local Salvador)
Junio	Epic	TFM-3	Adquisición y Preparación de Datos
Junio	Epic	TFM-4	Dataset Consolidado y Etiquetado


Junio	Historia	TFM-25	Validación cruzada y cálculo de acuerdo entre jueces
Junio	Epic	TFM-5	Desarrollo Experimental y Fine-Tuning
Junio	Historia	TFM-26	Implementación de modelos base (Baselines)
Junio	Historia	TFM-27	Fine-Tuning de mBERT con datos locales
Junio	Historia	TFM-28	Fine-Tuning de XLM-RoBERTa con datos locales
Julio	Historia	TFM-29	Ajuste de hiperparámetros y optimización
Julio	Historia	TFM-30	Evaluación de rendimiento (Cross-Validation)
Julio	Historia	TFM-31	Modelos Entrenados y Evaluados
Agosto	Epic	TFM-6	Análisis y Sistema Funcional
Agosto	Epic	TFM-7	Prototipo Funcional de Clasificación
Agosto	Historia	TFM-32	Análisis comparativo de métricas (F1, Precision)


Agosto	Historia	TFM-33	Análisis de errores cualitativo (Jerga salvadoreña)
Agosto	Historia	TFM-34	Desarrollo de API y Backend del sistema
Agosto	Historia	TFM-35	Diseño de interfaz de usuario (Dashboard)
Agosto	Epic	TFM-8	Redacción Documentación de Tesis
Agosto	Historia	TFM-36	Redacción de Metodología y Resultados
Septiembre	Historia	TFM-37	Integración del documento final (Tesis)
Septiembre	Historia	TFM-38	Revisión por asesores y correcciones
Septiembre	Epic	TFM-9	Documentación de Tesis Lista
Septiembre	Epic	TFM-10	Preparación de Defensa

Septiembre	Historia	TFM-39	Preparación de material y diapositivas
Octubre	Historia	TFM-40	Simulacros de defensa técnica
Octubre	Epic	TFM-11	Material de Defensa Listo
Octubre	Epic	TFM-12	Pruebas y Validación
Octubre	Historia	TFM-41	Pruebas integrales del sistema
Octubre	Historia	TFM-42	Validación de resultados lingüísticos
Octubre	Historia	TFM-43	Pruebas de seguridad y acceso
Octubre	Historia	TFM-44	Pruebas de rendimiento del modelo
Octubre	Historia	TFM-45	Corrección de observaciones del sistema
Noviembre	Epic	TFM-13	Certificación de calidad del prototipo

Noviembre	Epic	TFM-14	Implementación y Capacitación
Noviembre	Historia	TFM-46	Migración de modelos a entorno productivo
Noviembre	Historia	TFM-47	Instalación final en servidor
Noviembre	Historia	TFM-48	Capacitación sobre el uso del sistema
Noviembre	Historia	TFM-49	Entrega de manuales de usuario
Noviembre	Historia	TFM-50	Ajustes finales de interfaz
Noviembre	Epic	TFM-15	Sistema operativo y usuarios capacitados
Noviembre	Epic	TFM-16	Cierre y Soporte Inicial
Noviembre	Historia	TFM-51	Monitoreo de clasificación post-entrega
Noviembre	Historia	TFM-52	Resolución de incidencias finales
Noviembre	Historia	TFM-53	Elaboración de informe final de proyecto

Noviembre	Epic	TFM-17	Proyecto cerrado y defensa completada
-----------	------	--------	---------------------------------------





Recursos necesarios y riesgos

Recursos Necesarios:

- ❖ **Hardware/Cloud:** Servidores con capacidad GPU (ej. Google Colab Pro, AWS EC2, o Azure) para el entrenamiento de los Transformers.
- ❖ **Software/Datos:** Credenciales de la API de X y Facebook Graph API. Entornos de desarrollo en Python (PyTorch/Hugging Face).
- ❖ **Humanos:** Investigadores para el etiquetado manual y validación del contexto salvadoreño.

Riesgos Identificados:

- ❖ **Riesgos externos:** Restricciones de acceso a datos de Facebook (Graph API limitada). Cambios en las políticas de privacidad y scraping.
- ❖ **Riesgos humanos:** Mayor complejidad en el etiquetado debido a los distintos tipos de texto. Posible sesgo en la interpretación de los comentarios largos de Facebook.
- ❖ **Gestión:** Incremento en el tiempo de recolección y limpieza de datos. Necesidad de normalizar datos de diferentes plataformas.
- ❖ **Financieros:** Mayor costo computacional derivado de procesar un dataset más grande.
- ❖ **Riesgos de datos:** Los datasets públicos en español (HatEval, IberBench, etc.) están orientados a dialectos de España o México, lo que puede introducir sesgo hacia modismos no salvadoreños. Mitigación: el corpus salvadoreño manual actúa como etapa de domain adaptation que corrige este sesgo; se evaluará explícitamente la mejora mediante ablation study antes vs después de la segunda etapa de fine-tuning.
- ❖ **Riesgos de anotación:** El etiquetado manual del corpus salvadoreño puede presentar inconsistencias entre anotadores, especialmente en casos límite de sarcasmo o ironía. Mitigación: elaborar guías de anotación claras con ejemplos ambiguos resueltos, aplicar doble anotación y calcular Cohen's Kappa como métrica de calidad (umbral mínimo aceptable de 0.6).

- ❖ **Riesgos técnicos:** El desbalance de clases (pocas instancias de “amenazas/violencia” versus muchas de “no tóxico”) puede degradar el F1-score en clases minoritarias. Mitigación: aplicar class weighting en la función de pérdida, oversampling (SMOTE textual) o data augmentation con paráfrasis automáticas. Las diferencias estilísticas entre plataformas (textos cortos de X vs comentarios extensos de Facebook) pueden afectar la generalización; se controlará mediante estratificación en los conjuntos de entrenamiento y prueba.
- ❖ **Riesgos legales/éticos:** La recopilación manual de publicaciones públicas, aunque éticamente válida, requiere anonimización estricta de usuarios antes de cualquier publicación o difusión del corpus. El proyecto debe cumplir las normativas de protección de datos aplicables. Los datasets públicos utilizados tienen licencias abiertas (Creative Commons o similares) que permiten su uso en investigación académica, lo que reduce el riesgo legal frente al scraping automatizado.

Bibliografía

- Conneau, A., et al. (2020). *Unsupervised Cross-lingual Representation Learning at Scale* (XLM-R). Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics.
- Devlin, J., et al. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL-HLT.
- Wirth, R., & Hipp, J. (2000). *CRISP-DM: Towards a standard process model for data mining*. Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining.
- Basile, V., et al. (2019). *SemEval-2019 Task 5: Multilingual Detection of Hate Speech Against Immigrants and Women in Twitter (HatEval)*. Proceedings of the 13th International Workshop on Semantic Evaluation (SemEval-2019). Hugging Face Hub: huggingface.co/datasets/valeriobasile/HatEval
- Tonneau, M. (2023). *Spanish Hate Speech Superset*. Hugging Face Hub: huggingface.co/datasets/manueltoneau/spanish-hate-speech-superset
- IberBench Team. (2024). *IberBench: A Benchmark for Iberian Languages Including DETOXIS Toxicity Detection*. Hugging Face Hub: huggingface.co/datasets/iberbench/iberbench_all
- Logacheva, V., et al. (2022). *Multilingual Toxicity Dataset (TextDetox)*. Hugging Face Hub: huggingface.co/datasets/textdetox/multilingual_toxicity_dataset
- Pérez, J. M., et al. (2022). *RoBERTuito: A pre-trained language model for social media text in Spanish*. Proceedings of LREC 2022. Hugging Face Hub: huggingface.co/pysentimiento/robertuito-hate-speech
- TextDetox. (2024). *XLM-R Large Toxicity Classifier*. Hugging Face Hub: huggingface.co/textdetox/xlmr-large-toxicity-classifier
- Wolf, T., et al. (2020). *Transformers: State-of-the-Art Natural Language Processing*. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, pp. 38–45.