Ficha Técnica Oficial del Modelo

`xlmr-hate-speech-sv` (Versión 4 - Especificaciones Técnicas Avanzadas)

Julio Enrique De La Quadra Mata
Cristian Antonio Escalante Hernández
Willian Alexander Chávez Servellón
Universidad de El Salvador — Facultad de Ingeniería y Arquitectura
Escuela de Sistemas Informáticos

Ciudad Universitaria, 6 de noviembre de 2026

1 1. Resumen y Datos Generales

Esta ficha técnica detalla las especificaciones arquitectónicas, el rendimiento cuantitativo, la reproducibilidad y el marco ético del modelo de clasificación de texto orientado a la detección de contenido tóxico y discurso de odio en español.

Nombre del Modelo	`xlmr-hate-speech-sv`
Versión	4.0 (Oficial / Blindada contra Fugas)
Repositorio Oficial	`https://huggingface.co/TheArbite/xlmr-hate-speech-sv`
Arquitectura Base	`xlm-roberta-base` (Transformer multilingüe)
Tipo de Tarea	Clasificación de secuencia de etiqueta única (*Single-Label Classification*)
Idioma	Español (Ajustado para modismos y jergas regionales)
Entorno Tecnológico	PyTorch, Hugging Face Transformers, Datasets, Hugging Face Hub API

2 2. Taxonomía de Clases

El modelo clasifica los textos de entrada en cuatro categorías mutuamente excluyentes:

ID (`label`)	Etiqueta Nominal	Definición Operativa
`0`	No Tóxico	Contenido estándar, neutro o coloquial sin presencia de ofensa.
`1`	Lenguaje Ofensivo	Uso de groserías o insultos de carácter informal sin odio sistémico.
`2`	Discurso de Odio	Expresiones denigrantes o discriminatorias basadas en características protegidas.
`3`	Amenazas/Violencia	Incitación explícita o implícita a la agresión o daño físico.

3 3. Datos y Rigor Metodológico

- **Corpus de Entrenamiento:** $37{,}829$ muestras saneadas y normalizadas (`train_oficial_limpio.csv`).
- **Banco de Prueba Ciego:** $4{,}727$ muestras en `test_oficial_limpio.csv`.
- **Control de Fugas (*Data Leakage*):** Verificado mediante intersección estricta de conjuntos disjuntos ($S_{train} \cap S_{test} = \emptyset$), garantizando **cero coincidencias exactas** y métricas de generalización reales.

4 4. Métricas Oficiales de Rendimiento

Evaluado sobre el conjunto de prueba independiente ($N = 4{,}727$):

Métrica Evaluada	Valor Oficial
Accuracy Global	**86.91%**
F1-Score Macro Promedio	**82.08%**
F1-Score Ponderado	**86.82%**
Tasa de Error Global	13.09%

5 5. Especificaciones Técnicas y de Arquitectura

Los detalles de implementación del motor de aprendizaje profundo comprenden:

- **Backbone Arquitectónico:** Basado en capas de atención bidireccional de XLM-RoBERTa (*Cross-lingual Language Model Robustly Optimized BERT Approach*), con un tamaño de embedding oculto de $d_{\text{model}} = 768$ y 12 capas de transformadores codificadores.
- **Capa de Clasificación (Head):** Capa lineal densa conectada al token especial `[CLS]`, proyectando las representaciones latentes de 768 dimensiones hacia las 4 clases de salida.
- **Tipado y Configuración de Tensores:** Forzado explícito de la variable objetivo a formato entero de 32 bits (`int32`/`int64`) y tipificación en el archivo de configuración con el parámetro `problem_type = "single_label_classification"`.
- **Tokenización:** Empleo del algoritmo basado en subpalabras *SentencePiece* con vocabulario de 250,000 tokens, configurado con una longitud máxima de secuencia (`max_length`) de 128 tokens, estrategia de relleno dinámico (*padding*) y truncamiento activo.

6 6. Hiperparámetros y Entorno de Entrenamiento

- **Optimizador:** Algoritmo AdamW con descomposición de peso (*weight decay*) y tasa de aprendizaje inicial constante de 2×10^{-5}.
- **Gestión de Lotes:** Tamaño de lote por dispositivo (*per-device batch size*) optimizado para estabilidad en gradientes.
- **Estrategia de Parada y Guardado:** Evaluación por época (*epoch*) con selección de mejores pesos fundamentada estrictamente en la maximización del *F1-Score Macro*.
- **Infraestructura de Hardware:** Entorno acelerado por GPU (NVIDIA con soporte CUDA) bajo Jupyter Lab / Google Colab.

7 7. Reproducibilidad y Gestión de Artefactos

- **Control de Semillas:** Inicialización estricta de la semilla aleatoria en biblioteca base y PyTorch (`torch.manual_seed(42)`).
- **Control de Versiones y Despliegue:** Sincronización automatizada mediante la API de Hugging Face Hub (`HfApi().upload_folder`), empaquetando pesos en formato seguro `model.safetensors`, metadatos de etiquetas en `config.json` y archivos del tokenizador.

8 8. Consideraciones Éticas y Riesgos Potenciales

- **Mitigación de Sesgos:** Uso de un corpus multilingüe robusto adaptado a jergas regionales para reducir la dependencia de español peninsular estándar.
- **Ambigüedad Semántica y Falsos Positivos:** La tasa de error residual (13.09%) concentra sus fallas en modismos coloquiales e ironías con alto peso léxico.
- **Uso Responsable:** Diseñado como soporte analítico para moderación; se desaconseja su uso como tomador de decisiones autónomo sin supervisión humana (*Human-in-the-Loop*).