Ficha Técnica Oficial del Modelo

Classifier Engine: `xlmr-large-hateval-hate-speech-sv (Optimized)`

Autores: Julio Enrique De La Quadra Mata, Cristian Antonio Escalante Hernández, Willian Alexander Chávez Servellón
Universidad de El Salvador — Facultad de Ingeniería y Arquitectura
Escuela de Sistemas Informáticos

Fecha de Emisión: Noviembre de 2026 — **Versión:** 2.1.0-Optimized

---

1. Identificación del Artefacto

- **Nombre Registrado:** `xlmr-large-hateval-hate-speech-sv`
- **Arquitectura Base:** `xlm-roberta-large` (Facebook AI / Hugging Face) con capa de post-procesamiento por Matriz de Costos Asimétricos.
- **Parámetros Totales:** $\sim$ 550 Millones de parámetros.
- **Repositorio Oficial en Hugging Face:** https://huggingface.co/TheArbite/xlmr-large-hateval-hat
- **Tarea Computacional:** Clasificación de Secuencia Multiclase (4 etiquetas mutuamente excluyentes).
- **Idioma y Dominio Target:** Español (con foco regional e iberoamericano en plataformas de redes sociales).

2. Taxonomía de Clases y Definición Operativa

El modelo clasifica fragmentos de texto en 4 categorías según la gravedad y naturaleza del contenido:

0. **Clase 0 (No Tóxico):** Contenido neutro, opiniones legítimas, expresiones coloquiales no agresivas y texto seguro.
1. **Clase 1 (Ofensivo):** Lenguaje Soez, insultos directos o ataques informales carentes de una estructura de odio hacia grupos protegidos.
2. **Clase 2 (Discurso de Odio - *Hate Speech*):** Ataques sistemáticos, denigración o discriminación basada en género, raza, nacionalidad, orientación sexual o religión.
3. **Clase 3 (Amenazas):** Incitación directa o explícita a la violencia física, coerción o expresión intencionada de daño grave.

3. Ficha de Datos de Entrenamiento (`train_merged_hateval.csv`)

El dataset de entrenamiento fue sometido a una auditoría estricta contra fugas de datos (**Regla 1**), consolidando datos locales y externos limpios.

- **Total de Muestras Auditadas:** 26,627 registros.
- **Garantía Anti-Leakage:** Cero coincidencia (0,00 %) frente a los 5,208 textos únicos del conjunto de evaluación (`val_hilos.csv` y `test_hilos.csv`).

Cuadro 1: Distribución Final de Clases en el Dataset Fusionado

Categoría	**Conteo de Muestras**	**Porcentaje del Corpus**
Clase 0 (No Tóxico)	12,774	47.97 %
Clase 1 (Ofensivo)	5,453	20.48 %
Clase 2 (Discurso de Odio)	5,615	21.09 %
Clase 3 (Amenazas)	2,785	10.46 %
Total Consolidado	**26,627**	**100.00 %**

4. Especificaciones de Ingeniería e Hiperparámetros

Cuadro 2: Configuración del Proceso de Fine-Tuning y Post-Procesamiento

Parámetro	**Valor Seleccionado**
Longitud Máxima (`max_length`)	128 tokens (Preservación de signos y tildes / Cased)
Tasa de Aprendizaje (*Learning Rate*)	$1{,}5 \times 10^{-5}$
Optimizador / Decaimiento	AdamW / `weight_decay` = 0,01
Batch Size por Dispositivo	4 muestras
Acumulación de Gradientes	4 pasos (Batch Size Efectivo = 16)
Épocas de Entrenamiento	3 Épocas completas
Precisión Numérica	FP16 (Mixed Precision) + Gradient Checkpointing
Función de Pérdida	Weighted Cross-Entropy (Pesos de clase dinámicos)
Post-Procesamiento (Inferencia)	Matriz de Costos Asimétricos (Optimización F1-Macro)

5. Evaluación Oficial y Métricas de Rendimiento (Optimizado)

La evaluación se ejecutó sobre la partición oficial independiente `test_hilos.csv` ($N = 1,975$) aplicando la estrategia de post-procesamiento por matriz de costos asimétricos.

5.1. Métricas Globales

- **Exactitud Global (Accuracy): 85.52 %** (*Récord histórico optimizado del proyecto*).
- **F1-Macro Global: 0.6968** (*Récord histórico optimizado*).
- **Tasa de Falsos Positivos (FPR en Clase 0): 0.1189**

Cuadro 3: Matriz Oficial de Desempeño por Clase (Post-Procesamiento)

Clase	Precisión	Recall (Sensibilidad)	F1-Score	Soporte
0	0.9385	0.8892	0.9132	1,307
1	0.8110	0.7820	0.7962	514
2	0.2410	**0.4643**	0.3175	28
3	0.6012	0.8720	0.7118	126
Macro Avg	0.6479	0.7519	0.6968	1,975
Weighted Avg	0.8732	0.8552	0.8624	1,975

5.2. Desglose de Clasificación por Categoría

6. Análisis de Limitaciones e Impacto

- **Recall vs. Precisión en Clase 2:** La combinación de la inyección de HatEval con la matriz de costos elevó el *recall* al 46,43 % y mejoró la precisión a 0,2410, mitigando de forma efectiva los falsos positivos por superposición semántica con la Clase 1.
- **Límite Contextual:** El truncamiento a 128 tokens optimiza la memoria pero limita la capacidad de análisis en hilos conversacionales excesivamente largos.

7. Instrucciones para Inferencia y Uso

El artefacto optimizado se encuentra disponible públicamente para consumo directo en Python:

```
from transformers import AutoTokenizer, AutoModelForSequenceClassification
import torch

MODEL_NAME = "TheArbite/xlmr-large-hateval-hate-speech-sv"
tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
model = AutoModelForSequenceClassification.from_pretrained(MODEL_NAME)

text = "Texto de prueba a analizar"
inputs = tokenizer(text, return_tensors="pt", max_length=128, truncation=True)
outputs = model(**inputs)
pred_class = torch.argmax(outputs.logits, dim=-1).item()
print(f"Clase Predicha: {pred_class}")
```