Informe Metodológico y Documentación Técnica de Implementación: Modelo XLM-RoBERTa (`xlmr-hate-speech-sv` v4)

Julio Enrique De La Quadra Mata
Cristian Antonio Escalante Hernández
Willian Alexander Chávez Servellón
Universidad de El Salvador — Facultad de Ingeniería y Arquitectura
Escuela de Sistemas Informáticos

Ciudad Universitaria, 6 de noviembre de 2026

1 Resumen Metodológico

El presente documento detalla el proceso técnico, las decisiones de diseño de software y el pipeline de ingeniería de aprendizaje automático implementado en el desarrollo, saneamiento y despliegue del modelo clasificador **`xlmr-hate-speech-sv` (Versión 4 Oficial)**.

La arquitectura se fundamenta en un proceso de ajuste fino (*fine-tuning*) del modelo de lenguaje preentrenado **XLM-RoBERTa (`xlm-roberta-base`)**, enfocado en la categorización multiclase de textos en español con especial énfasis en el procesamiento de modismos, jergas y estructuras sintácticas regionales.

2 Arquitectura de Datos y Pipeline de Curación

2.1 Taxonomía de Clases y Codificación

El problema se formalizó como una tarea de **clasificación de secuencia de etiqueta única (*Single-Label Sequence Classification*)** sobre cuatro categorías mutuamente excluyentes:

ID (`label`)	Etiqueta Nominal	Definición Operativa
`0`	No Tóxico	Contenido estándar, neutro o coloquial sin presencia de elementos ofensivos o de odio.
`1`	Lenguaje Ofensivo	Uso de groserías, vulgaridades o insultos dirigidos de carácter informal sin incitación al odio sistemático.
`2`	Discurso de Odio	Expresiones denigrantes, deshumanizantes o discriminatorias basadas en características protegidas.
`3`	Amenazas/Violencia	Declaraciones explícitas o implícitas que incitan, proyectan o expresan intención de daño físico o violencia.

2.2 Saneamiento y Aislamiento Estricto de Particiones

Para garantizar la validez estadística de los experimentos, el corpus completo se sometió a un protocolo de filtrado y particionado con **intersección nula**:

1. **Estructuración de Datasets:** *Train* ($N = 37{,}829$) y *Test Oficial* ($N = 4{,}727$).
2. **Normalización:** Mapeo explícito de la variable objetivo a entero de 32 bits para evitar inconsistencias de dimensiones o *broadcasting*.
3. **Verificación de Aislamiento:** Evaluación de pertenencia mediante conjuntos disjuntos ($S_{train} \cap S_{test} = \emptyset$), confirmando 0 coincidencias exactas.

3 Configuración del Entorno de Modelado y Entrenamiento

3.1 Carga e Inicialización de la Arquitectura

El modelo se inicializó sobre el *backbone* de `xlm-roberta-base` con su respectivo mapeo de etiquetas:

```
from transformers import AutoModelForSequenceClassification, AutoTokenizer

MODEL_NAME = "xlm-roberta-base"

id2label = {
    0: "No Toxico",
    1: "Lenguaje Ofensivo",
    2: "Discurso de Odio",
    3: "Amenazas/Violencia"
}
label2id = {v: k for k, v in id2label.items()}
```

```
model = AutoModelForSequenceClassification.from_pretrained(
    MODEL_NAME,
    num_labels=4,
    id2label=id2label,
    label2id=label2id,
    problem_type="single_label_classification"
)
tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
```

3.2 Hiperparámetros y Estrategia de Optimización

El entrenamiento se estructuró bajo los siguientes parámetros clave:

- **Estrategia de Evaluación:** Evaluación al término de cada época (epoch).
- **Métrica de Optimización:** F1-Score Macro para mitigar el desequilibrio en clases minoritarias.
- **Control de Versiones:** Exclusión del tokenizador explícito en el constructor de `Trainer` para asegurar compatibilidad con versiones recientes.

4 Proceso de Inferencia y Resultados de Evaluación

4.1 Métricas Oficiales de Desempeño

La evaluación sobre el conjunto de prueba independiente ($N = 4{,}727$) arrojó los siguientes resultados:

- **Accuracy Global:** 86.91%
- **F1-Macro Promedio:** 82.08%
- **Tasa de Error Global:** 13.09%

4.2 Reporte de Clasificación y Matriz de Confusión

	precision	recall	f1-score	support
No Toxico	0.8519	0.8827	0.8670	1407
Lenguaje Ofensivo	0.9062	0.9126	0.9094	2404
Discurso de Odio	0.8177	0.7513	0.7831	591
Amenazas/Violencia	0.7475	0.7015	0.7238	325
accuracy			0.8691	4727
macro avg	0.8308	0.8120	0.8208	4727
weighted avg	0.8681	0.8691	0.8682	4727

La matriz de confusión absoluta se define como:

$$\boldsymbol{M} = \begin{bmatrix} 1242 & 89 & 33 & 43 \\ 132 & 2194 & 53 & 25 \\ 38 & 100 & 444 & 9 \\ 46 & 38 & 13 & 228 \end{bmatrix}$$

5 Análisis Cualitativo del Error Residual

La tasa de error del 13.09% (619 muestras) evidencia que las discrepancias obedecen a la complejidad semántica natural del lenguaje coloquial:

1. **Solapamiento entre Ofensa y Odio (100 casos):** Ambigüedades en adjetivaciones fuertes y metáforas deshumanizantes.
2. **Falsos Positivos/Negativos en No Tóxico (221 casos acumulados):** Modismos regionales e ironías no dirigidas.
3. **Ambigüedad en Amenazas:** Refranes morales interpretados literalmente por el modelo debido a vocablos punitivos.

6 Limitaciones del Modelo

A pesar de la robustez lograda tras el saneamiento, se identifican las siguientes limitaciones operativas y conceptuales:

- **Evolución Lingüística:** El modelo puede mostrar resistencia o desactualización frente a nuevos modismos, jerga emergente o neologismos digitales que no formaban parte del corpus de entrenamiento.
- **Ambigüedad Contextual y Sarcasmo:** Expresiones altamente sarcásticas, irónicas o dobles sentidos complejos representan un desafío constante para los clasificadores basados en transformadores basados exclusivamente en texto plano.
- **Sensibilidad a Clases Minoritarias:** Aunque el F1-Macro se optimizó con éxito, las clases con menor soporte (*Amenazas/Violencia* y *Discurso de Odio*) conservan una tasa de error superior en comparación con las clases mayoritarias.

7 Conclusiones

1. Se implementó con éxito un pipeline de reentrenamiento robusto sobre la arquitectura XLM-RoBERTa, logrando superar satisfactoriamente las vulnerabilidades metodológicas previas mediante el aislamiento absoluto de particiones (cero fugas de datos).

2. El modelo alcanzó métricas altamente competitivas (86.91% de Accuracy y 82.08% de F1-Macro) evaluadas sobre un banco de pruebas independiente y ciego, garantizando una capacidad de generalización real.

3. La sincronización y despliegue de los artefactos en el Hugging Face Hub consolidan un flujo de trabajo reproducible, estandarizado y listo para integración en entornos de producción o auditoría.

8 Recomendaciones

- **Actualización Periódica del Corpus:** Incorporar ciclos continuos de etiquetado y reentrenamiento para capturar la evolución del lenguaje coloquial y evitar la obsolescencia del modelo.

- **Implementación de un Sistema Human-in-the-Loop:** Establecer un mecanismo de revisión humana para aquellas predicciones que se encuentren en zonas de umbral de confianza gris (especialmente entre lenguaje ofensivo y discurso de odio).

- **Exploración de Modelos de Mayor Escala:** Evaluar futuros incrementos de rendimiento mediante la experimentación con arquitecturas multilingües de mayor capacidad de parámetros o técnicas de ensamblaje (*ensembling*).

9 Recursos Usados

- **Framework de Aprendizaje Profundo:** PyTorch y Hugging Face Transformers.

- **Hardware y Entorno de Desarrollo:** Google Colab / Jupyter Lab con soporte de aceleración por GPU.

- **Modelo Base:** `xlm-roberta-base` (Hugging Face Hub).

- **Datasets de Trabajo:** `train_oficial_limpio.csv` ($N = 37{,}829$) y `test_oficial_limpio.csv` ($N = 4{,}727$).

- **Plataforma de Despliegue y Control:** Hugging Face Hub (`TheArbite/xlmr-hate-speech-sv`).