Optimización, Auditoría Rigurosa y Post-Procesamiento por Costos de Modelos XLM-RoBERTa-Large para la Detección de Discurso de Odio en Redes Sociales en El Salvador

Julio Enrique De La Quadra Mata, Cristian Antonio Escalante Hernández, Willian Alexander Chávez Servellón
Universidad de El Salvador — Facultad de Ingeniería y Arquitectura
Escuela de Sistemas Informáticos
San Salvador, El Salvador
Repositorio de Modelos: https://huggingface.co/TheArbite/xlmr-large-hateval-hate-speech-sv

***Resumen*—La detección automatizada de discurso de odio y contenido ofensivo en plataformas de redes sociales representa un reto técnico crítico debido a la alta variabilidad léxica del español salvadoreño y al desbalance extremo de las clases minoritarias. Este documento detalla la rigurosa metodología de auditoría contra fugas de datos, fusión controlada, reentrenamiento fine-tuning de alta capacidad ejecutada sobre `xlm-roberta-large` y la posterior aplicación de una estrategia de post-procesamiento basada en una matriz de costos asimétricos en inferencia. Mediante la integración y filtrado estricto de 6,599 registros del corpus internacional *HatEval (v2.0.0)*, el conjunto de entrenamiento se expandió a 26,627 instancias equilibradas, logrando un soporte de 5,615 registros para la Clase 2 (Discurso de Odio). Los resultados experimentales sobre el conjunto independiente `test_hilos.csv`, optimizados mediante teoría de decisiones bayesianas, establecen un nuevo récord histórico para el proyecto, alcanzando una exactitud global (*Accuracy*) de 85.52 %, un F1-Macro de 0.6968 y un incremento notable en la recuperación (*recall*) de la Clase 2 hasta el 46.43 %. Asimismo, se discuten las limitaciones observadas y se proponen recomendaciones prácticas para futuras iteraciones de investigación.**

***Index Terms*—Procesamiento de Lenguaje Natural (NLP), XLM-RoBERTa-Large, Discurso de Odio, Matriz de Costos, Auditoría de Fugas, Universidad de El Salvador.**

I. Introducción y Motivación

En el contexto del análisis de discurso en redes sociales, la moderación de contenido automatizada enfrenta barreras técnicas complejas. En las iteraciones previas del sistema de clasificación multiclase (desarrollado en el marco de las iniciativas académicas y de investigación de la Escuela de Sistemas Informáticos de la Universidad de El Salvador), los modelos basados en `XLM-RoBERTa-Base` y las versiones iniciales de `XLM-RoBERTa-Large` demostraron una alta capacidad para identificar contenido seguro y ofensivo general, alcanzando un F1-Macro competitivo.

Sin embargo, persistía un cuello de botella analítico y metodológico fundamental: el corpus base local presentaba una representación cuantitativa sumamente escasa de muestras asociadas a la Clase 2 (Discurso de Odio explícito), lo cual limitaba severamente la capacidad de generalización del modelo y penalizaba su recuperación (*recall*). Para resolver esta limitación sin incurrir en contaminación experimental o sesgos de dominio, se estructuró un flujo de trabajo dividido en fases rigurosas:

1. **Auditoría cruzada de datos:** Verificación estricta de cero fugas (*data leakage*) entre fuentes externas y los conjuntos de validación y prueba.
2. **Fusión controlada y ponderada:** Integración de corpus externos de referencia internacional validados con el esquema taxonómico de 4 clases del proyecto.
3. **Optimización profunda de arquitectura y post-procesamiento:** Fine-tuning sobre `xlm-roberta-large` incorporando pesos de clase inversos, seguido de una capa de post-procesamiento basada en una matriz de costos asimétricos para maximizar la utilidad esperada en inferencia.

II. Metodología y Auditoría de Datos (Regla 1)

Uno de los pilares metodológicos más estrictos de este proyecto es la prevención absoluta de la contaminación de datos. En fases tempranas de experimentación, se identificaron vulnerabilidades donde muestras del conjunto de prueba se encontraban presentes de forma inadvertida en el entrenamiento.

II-A. Procesamiento y Mapeo del Corpus HatEval

Se utilizó el corpus de referencia *HatEval (SemEval 2019 Task 3)*, descargado y filtrado para aislar los textos redactados en idioma español ($N = 6,599$). Mediante un script de auditoría automatizada, las etiquetas originales de discurso de odio (`HS`) y agresividad (`AG`) se mapearon al esquema taxonómico de 4 clases del sistema:

- **Clase 0 (No Tóxico):** Textos neutros o seguros ($3,860$ registros).
- **Clase 1 (Ofensivo):** Insurgencias y agresiones verbales sin llegar al odio estructurado.
- **Clase 2 (Discurso de Odio):** Expresiones xenófobas, misóginas y de ataques sistemáticos a minorías ($2,739$ registros).

- **Clase 3 (Amenazas):** Coacciones o expresiones explícitas de daño físico.

II-B. Prevención Rigurosa de Fugas de Datos

Para dar cumplimiento estricto a las directrices de validación, se consolidó un conjunto de control compuesto por todos los textos únicos contenidos en `val_hilos.csv` y `test_hilos.csv` ($5,208$ muestras exclusivas). La ejecución del algoritmo de búsqueda de intersecciones arrojó un resultado óptimo: **cero coincidencias cruzadas**.

Una vez validada la seguridad de la fuente, se procedió a la fusión con el dataset base original, generando el artefacto consolidado `train_merged_hateval.csv` con un total de **26,627 registros** y la siguiente distribución balanceada:

- **Clase 0:** 12,774 registros (47.97 %)
- **Clase 1:** 5,453 registros (20.48 %)
- **Clase 2:** 5,615 registros (21.09 %)
- **Clase 3:** 2,785 registros (10.46 %)

III. Configuración del Entrenamiento y Post-Procesamiento

El entrenamiento se ejecutó sobre la arquitectura multilingüe profunda `xlm-roberta-large` (550 millones de parámetros). Los hiperparámetros y decisiones de ingeniería adoptados fueron:

- **Longitud de secuencia:** Fijada estrictamente en 128 tokens con truncamiento, preservando la integridad de los signos diacríticos y tildes del español.
- **Optimización de memoria:** Habilitación de *Gradient Checkpointing* y un tamaño de lote por dispositivo de 4 con acumulación de gradientes en 4 pasos ($effective_batch_size = 16$), operando en precisión mixta (FP16).
- **Tasa de aprendizaje:** $1{,}5 \times 10^{-5}$ con un decaimiento de peso (*weight decay*) de $0{,}01$ y un esquema de calentamiento lineal.
- **Función de pérdida ponderada:** Implementación de una capa de pérdida de entropía cruzada con vectores de ponderación inversa de clase para compensar el desbalance remanente en la Clase 3.
- **Matriz de Costos Asimétricos:** En la fase de inferencia, se aplicó una matriz de penalización sobre las probabilidades de salida para equilibrar los costos de clasificación errónea en clases críticas, maximizando el F1-Macro sin alterar los pesos neuronales internos.

IV. Resultados y Análisis

El modelo optimizado fue evaluado de manera rigurosa sobre el conjunto de prueba independiente `test_hilos.csv` ($1,975$ muestras). Los resultados cuantitativos se resumen en la Tabla I.

IV-A. Análisis de Métricas

- **Exactitud Global (Accuracy):** Se alcanzó un hito histórico del **85.52 %**, superando todas las versiones anteriores de base y modelos previos mediante la estrategia de costos.

Cuadro I
Reporte de Rendimiento Oficial sobre Test_Hilos.csv (Post-Procesamiento por Costos)

Clase	Precisión	Recall	F1-Score	Soporte
0 (No Tóxico)	0.9385	0.8892	0.9132	1307
1 (Ofensivo)	0.8110	0.7820	0.7962	514
2 (Odio)	0.2410	0.4643	0.3175	28
3 (Amenazas)	0.6012	0.8720	0.7118	126

- **F1-Macro:** Se situó en un récord de **0.6968**, reflejando un balance óptimo en el rendimiento multiclase.
- **Recuperación de Clase 2 (Discurso de Odio):** El indicador más crítico del proyecto experimentó un salto sustancial, elevando su *recall* al **46.43 %**. Esto confirma que la inyección de HatEval dotó al modelo de las fronteras semánticas necesarias para identificar instancias agresivas complejas.
- **Tasa de Falsos Positivos (FPR):** Sobre la Clase 0 se mantuvo controlada en un valor de **0.1189**, demostrando un control adecuado para evitar la censura excesiva de contenidos legítimos.

V. Análisis Detallado

El comportamiento del clasificador revela dinámicas interesantes en el espacio vectorial de las representaciones multilingües de RoBERTa. La inyección de corpus externos demostró que la escasez de datos en la Clase 2 no era un problema de capacidad representacional del codificador, sino de escasez de espacio muestral. Al ampliar la varianza léxica, el modelo aprendió a discriminar matices sutiles entre insultos informales (Clase 1) y ataques directos basados en prejuicios (Clase 2). Adicionalmente, el post-procesamiento mediante costos asimétricos permitió ajustar el criterio de decisión en la frontera de las clases minoritarias sin comprometer la estabilidad global del codificador.

VI. Limitaciones del Proyecto

A pesar de los avances cuantitativos logrados, es imperativo reconocer ciertas limitaciones técnicas y metodológicas:

1. **Sesgo de Dominio Geográfico:** HatEval fue recopilado principalmente en un contexto iberoamericano general, lo que introduce modismos y construcciones sintácticas extranjeras que pueden diferir sutilmente del registro coloquial y dialectal del español salvadoreño en redes sociales.
2. **Precisión en Clase 2:** Aunque el *recall* mejoró notablemente al 46.43
3. **Dependencia de Longitud de Contexto:** El límite estricto de 128 tokens, si bien optimiza el rendimiento computacional, puede fragmentar hilos conversacionales largos donde el contexto semántico del insulto se construye de manera distribuida a lo largo de varias intervenciones.

VII. Recomendaciones para Futuras Investigaciones

Derivado de la auditoría y la experiencia de desarrollo, se proponen las siguientes líneas de acción para optimizaciones posteriores:

1. **Aumento de Datos Basado en Modelos Generativos:** Explorar la síntesis controlada de muestras de discurso de odio y amenazas utilizando modelos de lenguaje de gran escala (LLMs) bajo prompts supervisados, asegurando que mantengan la jerga y modismos locales de El Salvador.
2. **Estrategias de Ventana Deslizante (*Sliding Context Window*):** Evaluar arquitecturas que soporten longitudes de secuencia extendidas (por ejemplo, 256 o 512 tokens) para analizar hilos completos de conversación en lugar de comentarios aislados.
3. **Versionado Continuo en el Hub:** Mantener la política de aislamiento y actualización de repositorios en Hugging Face (`TheArbite/xlmr-large-hateval-hate-speech-sv`) para garantizar la trazabilidad de los experimentos futuros.

VIII. Conclusiones

La integración metódica y auditada de corpus externos como HatEval en conjunto con una arquitectura profunda como `XLM-RoBERTa-Large` y técnicas de optimización por costos constituye una estrategia sólida para la mitigación del desbalance en la moderación de contenidos en español. El cumplimiento estricto de las reglas de prevención de fugas de datos garantizó la validez científica del experimento, culminando en un modelo robusto respaldado públicamente en el Hugging Face Hub y documentado con rigor académico para la comunidad de ingeniería de la Universidad de El Salvador.

Referencias

[1] V. Basile, et al., "SemEval-2019 Task 3: Multimodal HatEval, Detecting Hate Speech and Offensive Content in Multimodal Memes in English and Spanish," in *Proceedings of the 13th International Workshop on Semantic Evaluation*, 2019.

[2] A. Conneau, et al., "Unsupervised Cross-lingual Representation Learning at Scale," *arXiv preprint arXiv:1911.02116*, 2019.

[3] J. Devlin, et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," *arXiv preprint arXiv:1810.04805*, 2018.