

UNIVERSIDAD DE EL SALVADOR
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE SISTEMAS INFORMÁTICOS



2026

TEMA DE INVESTIGACIÓN

ETAPA II ANÁLISIS DEL DISCURSO DE ODIO EN REDES SOCIALES EN EL SALVADOR

Integrantes

Julio Enrique De La Quadra Mata

Cristian Antonio Escalante Hernandez

Willian Alexander Chávez Servellón

Ciudad universitaria, 12 de septiembre del 2026

Índice general

1	Introducción y Planteamiento	2
1.1	Alcance de esta etapa	2
1.2	Objetivo de la Etapa II	2
1.3	Objetivos específicos	3
1.4	Taxonomía	3
2	Metodología	3
3	Auditoría de la Entrega Anterior	4
4	Selección de Arquitectura	4
4.1	Adecuación del tokenizador al dialecto	4
4.2	Comparación controlada de siete arquitecturas	6
5	Corpus Dirigido	7
5.1	Diseño del generador	7
5.2	Composición	8
5.3	Higiene del corpus	8
5.4	Correcciones al pipeline compartido	8
6	Optimización de Hiperparámetros	9
6.1	Ablación de datos y de régimen de entrenamiento	10
7	Modelos Avanzados y Ensemble	12
7.1	Modelo individual	12
7.2	Ensemble por voto blando	12
8	Evaluación Rigurosa	13
8.1	Validación cruzada estratificada	13
8.2	Prueba final	14
8.3	Métricas por clase	15
8.4	Comparación pareada	17
8.5	Robustez ante evasión	17
8.6	Resistencia a la evasión deliberada	18
9	Análisis de Sesgos y Ética	20
9.1	Métricas por subgrupo	20
9.2	Brechas de paridad	20
9.3	Calibración	21
9.4	Interpretación	22
9.5	Consideraciones éticas del sistema	23
10	Prototipo Funcional	23
11	Impacto Social y Recomendaciones de Política Pública	25

11.1 El problema en el contexto salvadoreño	25
11.2 Aportes concretos de este trabajo	25
11.3 Recomendaciones de política pública	25
11.4 Lo que este trabajo no resuelve	27
12 Limitaciones	27
13 Conclusiones	28
14 Reproducibilidad y Evidencias	29
14.1 Repositorio	29
14.2 Verificación de integridad	29
15 Glosario	29
16 Anexos	30
16.1 Anexo A: Informe de auditoría de la entrega anterior	30
16.2 Anexo B: Informe técnico de resultados de la Etapa II	31
16.3 Anexo C: Artefactos de evaluación	31

1 Introducción y Planteamiento

1.1 Alcance de esta etapa

La Etapa I dejó el corpus salvadoreño construido, etiquetado y validado entre anotadores, con tres baselines clásicos como referencia. La Etapa II parte de ahí y aborda el modelado: qué arquitectura conviene a este problema, cómo debe ampliarse el corpus, qué hiperparámetros lo optimizan, y si el sistema resultante es lo bastante sólido y equitativo para presentarse como prototipo.

El punto de partida fueron dos modelos ya entrenados por el equipo, mBERT y XLM-RoBERTa, con F1-macro de 0.7777 y 0.8058 sobre el conjunto de prueba. Ninguno alcanzaba la meta de 0.80 con significancia estadística: el intervalo de confianza del mejor de los dos descendía hasta 0.7665. Esta etapa cierra esa brecha.

1.2 Objetivo de la Etapa II

Alcanzar un F1-macro de al menos 0.80 sobre el conjunto de prueba de forma defendible, entendiendo por defendible que el extremo inferior del intervalo de confianza del 95 % también supere ese umbral, y no solamente la estimación puntual.

1.3 Objetivos específicos

- Seleccionar la arquitectura con evidencia medida y no por convención, comparando siete modelos preentrenados bajo condiciones idénticas.
- Ampliar el corpus con datos sintéticos dirigidos a las debilidades efectivamente medidas, manteniendo intactos los conjuntos de validación y prueba.
- Optimizar hiperparámetros mediante búsqueda sistemática sobre el conjunto de validación.
- Evaluar con validación cruzada estratificada además de la prueba final única.
- Cuantificar sesgos por plataforma, registro dialectal, figura retórica y contexto.
- Entregar un prototipo funcional que aplique el mismo pipeline de inferencia del entrenamiento, sin divergencias.

1.4 Taxonomía

Se conservan las cuatro clases canónicas de la Etapa I, sin añadir ni fusionar ninguna: No Tóxico (0), Lenguaje Ofensivo (1), Discurso de Odio (2) y Amenazas/Violencia (3), con la precedencia Amenazas > Odio > Ofensivo > No Tóxico.

2 Metodología

La etapa sigue las fases de modelado y evaluación de CRISP-DM, con una fase previa de auditoría que no estaba prevista y que resultó determinante.

- Auditoría de la entrega anterior: reejecución independiente de los cuatro checkpoints entregados para verificar que las cifras publicadas se reproducen desde los pesos.
- Selección de arquitectura: análisis de adecuación del tokenizador y comparación controlada de siete modelos preentrenados.
- Preparación de datos: generación de corpus sintético dirigido y corrección de tres defectos del pipeline compartido.
- Modelado: ablación de datos y régimen de entrenamiento, optimización de hiperparámetros con Optuna y construcción de un ensemble por voto blando.
- Evaluación: validación cruzada estratificada de cinco pliegues, prueba final única, batería adversarial, sonda dirigida e informe de equidad.

- Despliegue: prototipo de inferencia con API e interfaz web.

Todo el código es determinista con semilla fija. Los conjuntos de validación y prueba se mantuvieron idénticos byte a byte a los de la etapa anterior, lo que hace que todas las cifras de este documento sean directamente comparables con las previas.

3 Auditoría de la Entrega Anterior

Antes de modelar nada se reejecutaron los cuatro checkpoints entregados por el equipo, cargando los pesos y corriendo la inferencia sobre el mismo conjunto de prueba. El propósito era comprobar que las cifras publicadas se reproducen.

Entrega	Cifras verificadas	Reproducibles
mBERT B2	26	26 de 26
Prototipo XLM-R V2	11	3 de 11

Tabla 1 Reproducibilidad de las cifras publicadas en la entrega anterior

La entrega de mBERT reprodujo todas sus cifras al cuarto decimal. La del prototipo XLM-R no reprodujo ninguna de las tres que declaraba como resultado, y la revisión del código de entrenamiento mostró por qué: veintiún textos del conjunto de prueba habían sido reinyectados en el conjunto de entrenamiento etiquetados como No Tóxico, y la mejora de la tasa de falsos positivos se medía después sobre esos mismos textos.

La auditoría también cuantificó una vulnerabilidad del filtro de reglas de ese prototipo: anteponer la palabra «gracias» a una amenaza la reclasificaba como No Tóxico en veinte de cada cien casos. Ese hallazgo motivó la decisión de no usar ninguna capa de reglas post-hoc en la Etapa II.

El informe completo de la auditoría, con la tabla de contraste cifra por cifra, se adjunta como anexo.

4 Selección de Arquitectura

4.1 Adecuación del tokenizador al dialecto

Antes de entrenar conviene medir cuánto le cuesta a cada modelo leer este registro. La fertilidad es el número medio de subtokens por palabra: cuanto más alta, más troceado queda el texto y menos contexto efectivo cabe en la ventana.

Modelo	Vocabulario	Fertilidad	UNK	Jerga como un token
RoBERTuito	30 K	1.470	0	108 / 1923 (5.6 %)
BERTIN	50 K	1.546	0	19 (1.0 %)
BETO	31 K	1.598	588	86 (4.5 %)
XLM-R base / large / TwitterXLM-R	250 K	1.696	3	45 (2.3 %)
mBERT	120 K	1.805	45	31 (1.6 %)
mDeBERTa-v3	250 K	1.851	45	40 (2.1 %)

Tabla 2 Adecuación del tokenizador medida sobre los 2,144 textos reales del corpus




Figura 1 Fragmentación del texto salvadoreño por tokenizador

La figura ordena los candidatos por cuánto trocean el mismo texto. La distancia entre los extremos es de 0.38 subtokens por palabra, un 26 % más de fragmentación en el peor caso que en el mejor. Dos modelos quedan marcados por motivos opuestos: RoBERTuito es el que menos trocea y el único que además cubre más del 5 % del léxico local como unidad, y BETO aparece con 588 tokens desconocidos, que es un defecto de otra naturaleza —no fragmenta, directamente no reconoce— y lo descarta.

mBERT, uno de los dos modelos elegidos en la Etapa I, resultó ser el peor tokenizador del grupo: gasta un 23 % más de subtokens que RoBERTuito sobre el mismo texto. «cerote» se parte en «cero ##te», «maje» en «maj ##e» y «pisto» en «pis ##to». BETO queda descartado por producir 588 tokens

desconocidos sobre el corpus.

El dato de fondo, sin embargo, es que ningún tokenizador conoce el dialecto: el mejor cubre apenas el 5.6 % del léxico salvadoreño como unidad léxica.

4.2 Comparación controlada de siete arquitecturas

Los siete candidatos se entrenaron con hiperparámetros idénticos sobre el mismo corpus y se evaluaron sobre el mismo conjunto de validación.

Modelo	F1-macro	Parámetros	Tiempo
TwitterXLM-R	0.8289	278 M	3.1 min
RoBERTuito	0.8272	109 M	1.5 min
BERTIN	0.8141	125 M	1.7 min
XLM-R large	0.8090	560 M	42.2 min
BETO	0.8000	110 M	1.6 min
XLM-R base	0.7895	278 M	2.0 min
mBERT	0.7636	178 M	2.1 min

Tabla 3 Comparación de arquitecturas con hiperparámetros idénticos (F1-macro sobre validación, $n = 459$)




Figura 2 Desempeño frente a tamaño del modelo, con el dominio de preentrenamiento destacado

La figura cruza el tamaño del modelo con su desempeño, y lo que muestra es que no hay relación. Si el tamaño explicara el resultado, los puntos subirían de izquierda a derecha; no lo hacen. Lo que sí separa a los dos mejores del resto es el color: ambos fueron preentrenados sobre publicaciones de redes sociales. El modelo más grande de la comparación, con 560 millones de parámetros, queda por debajo de uno cinco veces menor.

Dos conclusiones. La primera: escalar el modelo no resuelve este problema. XLM-R large tiene cinco veces los parámetros de RoBERTuito, tarda veintiocho veces más y obtiene menos F1. Con 2,144 ejemplos reales el cuello de botella no es la capacidad.

La segunda, que es la que explica el salto de esta etapa: el corpus de preentrenamiento importa más que la arquitectura. TwitterXLM-R es exactamente la misma arquitectura que XLM-R base, con el mismo tamaño y el mismo tokenizador, y le saca 0.039 de F1-macro por el solo hecho de haber sido preentrenado sobre publicaciones de redes sociales. Los dos modelos elegidos en la Etapa I resultaron ser los dos peores de la comparación.

5 Corpus Dirigido

5.1 Diseño del generador

El corpus se amplió con ejemplos sintéticos dirigidos a las debilidades que la auditoría había medido: amenazas ofuscadas, eufemismos locales de violencia, emojis como vehículo de ataque y falsos positivos ante jerga inofensiva.

El material de partida es el léxico salvadoreño del proyecto, reconstruido en 110 familias canónicas con sus 1,979 variantes de ofuscación. Son deformaciones observadas en el corpus real, no inventadas para el ejercicio.

Tres decisiones de diseño merecen constar, porque las tres corrigen defectos de la versión anterior del generador. Los portadores de frase son vocativos y aposiciones, que no exigen concordancia de género ni número, de modo que no se producen construcciones agramaticales que el modelo aprendería como señal. Cada emoji se empareja únicamente con referentes de su propio grupo, según el catálogo del proyecto, para no enseñar asociaciones falsas. Y cada término dialectal lleva su rol gramatical, porque «pisto» es un objeto, «chivo» un adjetivo y «puchica» una interjección, y colocarlos en el mismo hueco produce frases que no existen.

5.2 Composición

Origen	Registros
Publicaciones reales	2,144
Sintéticos de la versión anterior	1,142
Sintéticos dirigidos nuevos	2,916
Total de entrenamiento	6,202
Validación (sin modificar)	459
Prueba (sin modificar)	460

Tabla 4 Composición del corpus de entrenamiento

Los conjuntos de validación y prueba se copiaron sin tocar una sola etiqueta ni renormalizar un solo texto. Sus funciones resumen coinciden con las de la etapa anterior, lo que garantiza que las comparaciones de este documento son válidas y que ninguna mejora puede atribuirse a haber facilitado la prueba.

5.3 Higiene del corpus

Se verificó que ningún texto del entrenamiento coincide con validación, prueba o la batería adversarial. La verificación detectó siete filas que el proyecto arrastraba desde agosto, compartidas entre la batería y el entrenamiento, y que quedaron fuera.

La comprobación se hace también contra la normalización vigente del texto crudo y no solo contra la columna almacenada: una de las siete filas se había vuelto invisible porque la batería guardaba su texto normalizado con una versión anterior del normalizador.

5.4 Correcciones al pipeline compartido

La construcción del corpus destapó dos defectos del normalizador que afectaban a todo el proyecto.

Defecto	Efecto	Corrección
La anonimización de menciones no exigía límite de palabra	«m@tar» se convertía en «m@usuario»; la ofuscación con arroba, que es una de las evasiones a detectar, se destruía en la normalización	Se añadió una guarda de límite de palabra. El conjunto de prueba no cambia ni una fila
El emoji de pistola se traducía como «pistola de agua»	Es el nombre Unicode vigente, pero enseñaba «agua» donde el catálogo documenta un vehículo de amenaza	Se corrigió la traducción a «pistola»

Tabla 5 Defectos corregidos en el normalizador

6 Optimización de Hiperparámetros

Se ejecutaron veinte pruebas con Optuna, usando un muestreador TPE con semilla fija, optimizando F1-macro sobre el conjunto de validación. El conjunto de prueba no participó en la búsqueda ni se consultó durante ella.

Hiperparámetro	Rango explorado	Valor elegido
Tasa de aprendizaje	8×10^{-6} – 6×10^{-5} (log)	5.07e-05
Tamaño de lote	8 / 16 / 32	32
Épocas	3 – 6	4
Decaimiento de pesos	0.00 – 0.15	0.1342
Calentamiento	0.00 – 0.20	0.1365
Peso de los ejemplos sintéticos	0.25 / 0.50 / 0.75 / 1.00	1.0
Épocas finales solo con ejemplos reales	0 – 3	3
Ponderación por clase	sí / no	sí

Tabla 6 Espacio de búsqueda y configuración seleccionada

La mejor prueba alcanzó 0.8523 en validación frente a 0.8272 de la configuración por defecto, lo que sitúa la aportación de la búsqueda en +0.025. El rango entre

la mejor y la peor configuración fue de 0.0547, lo que da idea de cuánto dependía el resultado de unos valores que hasta ahora se habían fijado por convención.




Figura 3 Trayectoria de la búsqueda de hiperparámetros

La línea del mejor acumulado avanza a saltos: la mitad de las pruebas no mejora nada y el hallazgo llega en la prueba once. La nube de puntos se reparte casi seis puntos de F1 entre la mejor y la peor configuración, lo que dimensiona el riesgo de fijar los hiperparámetros por convención, como se había hecho hasta ahora.

La configuración ganadora resultó interesante por sí misma: peso completo a los ejemplos sintéticos durante el grueso del entrenamiento y tres épocas finales únicamente con ejemplos reales. El modelo aprovecha toda la señal de robustez que aportan los sintéticos y después se reasienta en la distribución que realmente se va a evaluar.

6.1 Ablación de datos y de régimen de entrenamiento

Antes de fijar la configuración se aisló el efecto de cada decisión, con la arquitectura y los hiperparámetros constantes.

Variante	TwitterXLM-R	RoBERTuito
Corpus anterior solamente	0.8331	0.8272
Corpus dirigido, peso 1.0	0.8080	0.8337
Corpus dirigido, peso 0.5	0.8094	0.8371
Corpus dirigido, peso 0.25	0.8144	0.8403

Variante	TwitterXLM-R	RoBERTuito
Corpus dirigido, dos fases	0.8090	0.8386
Corpus dirigido, peso 0.5 y dos fases	—	0.8473
Vocabulario extendido, corpus anterior	0.7756	0.8231
Vocabulario extendido, corpus dirigido	0.8016	0.8213

Tabla 7 Ablación de corpus, vocabulario y régimen (F1-macro sobre validación)




Figura 4 Efecto del corpus sintético según la capacidad del modelo

Las dos líneas se cruzan, y ese cruce es el hallazgo. Partiendo del corpus anterior, el modelo grande va por delante; en cuanto entran los ejemplos sintéticos, cae más de dos puntos y ya no se recupera, mientras que el pequeño sube de forma sostenida. Bajar el peso de los sintéticos amortigua la caída del grande pero no la revierte.

El resultado más informativo es que los mismos datos ayudan a un modelo y perjudican al otro. Con TwitterXLM-R, de 278 millones de parámetros, los sintéticos cuestan hasta 2.5 puntos; con RoBERTuito, de 109 millones, aportan hasta 2. La lectura es que el modelo grande tiene capacidad de sobra para memorizar la estructura de las plantillas, y esa estructura no existe en el lenguaje real; el pequeño no puede memorizarla y se queda con la señal.

La extensión del vocabulario con 189 tokens de dominio perjudicó en las seis

configuraciones probadas. La hipótesis era razonable, porque los marcadores de emoji se fragmentan en cuatro o más piezas, pero un token nuevo nace con un vector aleatorio y no hay ejemplos suficientes para aprenderlo: mientras tanto sustituye una representación imperfecta pero informativa por ruido. La vía se documenta como explorada y descartada.

Un subconjunto que conserva solo las familias dirigidas a una debilidad medida, con 1,292 filas menos, obtiene 0.8472 frente a 0.8473 del conjunto completo. Es decir, la mitad de los sintéticos generados era prescindible: los modelos ya acertaban entre el 68 % y el 89 % en insultos ofuscados, y añadir volumen donde no hay problema solo desplaza la distribución de entrenamiento.

7 Modelos Avanzados y Ensemble

Los siete candidatos evaluados son modelos de aprendizaje profundo de la familia Transformer, ajustados mediante transfer learning sobre el corpus salvadoreño. Seis son variantes de codificador bidireccional preentrenado —BERT multilingüe, BETO, BERTIN, RoBERTuito, XLM-RoBERTa en sus versiones base y large, y TwitterXLM-R— y se compararon bajo condiciones idénticas antes de elegir.

7.1 Modelo individual

El modelo final es RoBERTuito ajustado con la configuración óptima. Se entrenó con tres semillas y se seleccionó la mediana, no la mejor: quedarse con la semilla más favorable es una forma silenciosa de sobreajustar al conjunto de selección.

Semilla	F1-macro en validación
42	0.8374
1337	0.8409 (mediana, seleccionada)
2026	0.8555

Tabla 8 Dispersión entre semillas del modelo final

La dispersión entre semillas es de 1.8 puntos. Conviene tenerlo presente al leer cualquier comparación de este proyecto: varias de las «mejoras» reportadas en entregas anteriores son del mismo orden que el ruido de inicialización.

7.2 Ensemble por voto blando

Se construyó un ensemble promediando las probabilidades de varios modelos. Solo se combinaron modelos que difieren en algo real —semilla de inicialización

o corpus de preentrenamiento—, porque promediar réplicas idénticas no reduce varianza. La combinación se eligió sobre validación y el conjunto de prueba se consultó una sola vez, con la combinación ya fijada.

F1-macro en validación	Miembros
0.8519	roberTuito_s42 + roberTuito_s2026 + twitterXLMR_b2
0.8500	roberTuito_s2026 + twitterXLMR_b2
0.8491	roberTuito_s42 + roberTuito_s1337 + roberTuito_s2026
0.8487	roberTuito_s42 + roberTuito_s1337
0.8474	roberTuito_s42 + roberTuito_s1337 + roberTuito_s2026 + twitterXLMR_b2
0.8457	roberTuito_s1337 + roberTuito_s2026

Tabla 9 Combinaciones evaluadas sobre validación (seis mejores)

La combinación seleccionada fue roberTuito_s42 + roberTuito_s2026 + twitterXLMR_b2. Sobre validación obtiene 0.8519, prácticamente empatada con el mejor modelo individual (0.8555); sobre el conjunto de prueba la diferencia sí se materializa.

8 Evaluación Rigurosa

8.1 Validación cruzada estratificada

Se ejecutó una validación cruzada estratificada de cinco pliegues sobre los conjuntos de entrenamiento y validación unidos, reservando el conjunto de prueba como evaluación final única.

Los ejemplos sintéticos se asignan siempre al lado de entrenamiento y nunca aparecen en el pliegue de evaluación: medir sobre texto de plantilla inflaría artificialmente la métrica. Cada pliegue se evalúa exclusivamente sobre publicaciones reales.

Pliegue	Evaluado sobre	F1-macro
1	521 reales	0.8239
2	521 reales	0.7972

Pliegue	Evaluado sobre	F1-macro
3	521 reales	0.8650
4	520 reales	0.8326
5	520 reales	0.8397
Media $\pm$ desviación	2603 reales	0.8317 ± 0.0246

Tabla 10 Validación cruzada estratificada de cinco pliegues




Figura 5 Dispersión del F1-macro entre los cinco pliegues

La franja sombreada marca una desviación típica alrededor de la media. Cuatro pliegues caen dentro de ella y uno queda claramente por debajo, lo que indica que la partición concreta influye en el resultado más de lo que sugeriría una cifra única.

La media de 0.8317 con desviación 0.0246 corrobora el resultado de la prueba final y acota su incertidumbre. El rango entre pliegues (0.7972 a 0.8650) muestra que con este tamaño de corpus la partición concreta influye casi siete puntos, lo que refuerza la necesidad de reportar intervalos y no solo estimaciones puntuales.

8.2 Prueba final

Resultados sobre el conjunto de prueba, consultado una sola vez con los modelos ya seleccionados.

Sistema	F1-macro	IC 95 %	Aciertos	¿Meta con IC?
Ensemble	0.8656	[0.8322, 0.8968]	400/460	Sí
RoBERTuito individual	0.8499	[0.8164, 0.8824]	392/460	Sí
TwitterXLM-R (corpus anterior)	0.8302	[0.7940, 0.8633]	383/460	No
XLM-R v1 (Etapa I)	0.8058	[0.7665, 0.8420]	371/460	No
XLM-R mitigado	0.7887	[0.7486, 0.8257]	363/460	No
mBERT v1 (Etapa I)	0.7777	[0.7363, 0.8144]	360/460	No
mBERT B2	0.7610	[0.7172, 0.7983]	353/460	No

Tabla 11 Resultados sobre el conjunto de prueba ($n = 460$)




Figura 6 Comparación de los siete sistemas con su intervalo de confianza

La línea vertical marca la meta. Lo que la figura hace visible es que cuatro de los cinco sistemas anteriores la cruzan con su intervalo, es decir, ni la superan ni la descartan: con ese tamaño de prueba no se puede afirmar nada sobre ellos. Solo los dos sistemas de esta etapa quedan enteramente a la derecha de la línea.

La meta del proyecto se cumple en el criterio exigente: el extremo inferior del intervalo del ensemble se sitúa en 0.8322 y el del modelo individual en 0.8164, ambos por encima de 0.80. No pasa solo la estimación puntual; pasa el intervalo completo.

8.3 Métricas por clase

Clase	Precisión	Recall	F1	Soporte
No Tóxico	0.8793	0.8293	0.8536	123
Lenguaje Ofensivo	0.8774	0.8553	0.8662	159
Discurso de Odio	0.8100	0.8526	0.8308	95
Amenazas/Violencia	0.8202	0.8795	0.8488	83

Tabla 12 Métricas por clase del modelo individual sobre el conjunto de prueba




Figura 7 Matriz de confusión del modelo final

Los errores se concentran, como era de esperar, entre clases contiguas en la escala de gravedad. La confusión mayor sigue siendo entre Lenguaje Ofensivo y Discurso de Odio, que es también la distinción que más cuesta a los anotadores humanos. Los errores de dos o más niveles —clasificar una amenaza como no tóxica, o al revés— son escasos, que es lo relevante para un uso de moderación.

Las cuatro clases superan 0.83. Discurso de Odio, que era la peor clase en todos los modelos anteriores, con valores entre 0.7330 y 0.8041, sube a 0.8308.

Amenazas/Violencia pasa de un rango de 0.7349 a 0.7975 hasta 0.8488.

8.4 Comparación pareada

Prueba de McNemar exacta sobre las mismas 460 instancias.

Comparación	Solo acierta el nuevo	Solo acierta el anterior	p	Favorece
vs xlmr_v1	47	26	0.0186	modelo V3
vs mbert_b2	58	19	0.0000	modelo V3
vs xlmr_mit	52	23	0.0011	modelo V3

Tabla 13 Prueba de McNemar del modelo final frente a los modelos anteriores

Las tres comparaciones son estadísticamente significativas. Es la primera vez en el proyecto que una mejora reportada supera la prueba pareada.

8.5 Robustez ante evasión

Además de la prueba estándar se evaluaron dos conjuntos diagnósticos: la batería adversarial de 144 casos del proyecto y una sonda dirigida de 204 casos construida durante la auditoría, con ofuscación de groserías mediante asteriscos, arrobas, almohadillas y sustitución de letras por dígitos, amenazas de muerte literales y disfrazadas, eufemismos locales y emojis.

Conjunto	Modelo V3	mBERT B2	XLm-R v1	XLm-R mitigado
Batería adversarial (144)	125	120	74	77
Sonda dirigida (204)	200	167	105	112
Amenazas de muerte disfrazadas (72)	72	61	26	39
Emojis de amenaza (12)	12	12	0	0
Emoji inofensivo en texto amable (16)	16	16	5	8

Tabla 14 Conjuntos diagnósticos de robustez




Figura 8 Aciertos por familia de la sonda dirigida, frente a los modelos anteriores

La figura separa lo que la cifra global esconde. Los modelos anteriores no fallaban de forma pareja: se hundían en familias concretas —emojis de amenaza, amenazas disfrazadas, jerga inofensiva— y rendían bien en el resto. Las dos barras de emoji de amenaza del modelo XLM-R v1 no aparecen porque su acierto es cero.

Debe constar una advertencia metodológica: la sonda dirigida dejó de ser un conjunto independiente para el modelo de esta etapa. Cuatro de sus textos aparecen en el entrenamiento, y el 31 % de la sonda usa términos del mismo léxico con el que se generaron los ejemplos sintéticos. Excluyendo los cuatro textos el resultado es 196 de 200, pero la cifra que sí es limpia e independiente es el F1-macro sobre el conjunto de prueba, donde el solape con el entrenamiento es cero.

La sonda sigue siendo independiente para los cuatro modelos anteriores, que no vieron esos datos, por lo que la comparación entre columnas conserva su valor.

8.6 Resistencia a la evasión deliberada

La auditoría mostró que el filtro de reglas del prototipo anterior se desactivaba anteponiendo un marcador afectivo. Se repitió la prueba sobre el modelo de esta etapa con cien amenazas y seis prefijos.

Prefijo	Modelo V3	Prototipo anterior
(ninguno)	3 / 100	1 / 100
«gracias, »	5 / 100	20 / 100
«qué onda, »	5 / 100	19 / 100
«todo bien, »	7 / 100	17 / 100
«mi hermano, »	5 / 100	21 / 100
«buena onda, »	7 / 100	17 / 100

Tabla 15 Amenazas reclasificadas como No Tóxico al anteponer un marcador afectivo




Figura 9 Efecto de anteponer un marcador afectivo a cien amenazas

El contraste entre los dos grupos de barras es el argumento en contra de resolver el sesgo con reglas. Sin prefijo ambos sistemas se comportan de forma parecida; con prefijo, el que lleva filtro se degrada entre tres y cuatro veces más, porque la regla convierte el marcador afectivo en una llave.

El marcador afectivo degrada al modelo de esta etapa entre dos y cuatro casos de cien, que es la sensibilidad normal de cualquier clasificador al contexto. En el prototipo anterior lo degradaba entre dieciséis y veinte, porque la regla lo forzaba. Sin capa de reglas no hay puerta trasera.

9 Análisis de Sesgos y Ética

9.1 Métricas por subgrupo

El informe de equidad desagrega el desempeño por plataforma, registro dialectal, figura retórica, contexto y presencia de emoji. Se reportan F1-macro, tasa de falsos positivos —contenido inofensivo marcado como tóxico— y tasa de falsos negativos —contenido tóxico que pasa.

Corte	n	F1-macro	FPR	FNR
Plataforma X	228	0.9264	0.1458	0.0111
Plataforma Facebook	232	0.7783	0.2000	0.0510
Con jerga salvadoreña	278	0.8841	0.2759	0.0080
Sin jerga	182	0.7748	0.1489	0.0909
Sarcasmo: sí	90	0.6775	0.3125	0.0690
Sarcasmo: no	370	0.8859	0.1319	0.0215
Ironía: sí	59	0.5810	0.2069	0.0667
Ironía: no	401	0.8783	0.1702	0.0261
Contexto político: sí	92	0.9555	0.0625	0.0132
Contexto político: no	368	0.8478	0.1963	0.0345
Con emoji	26	0.3056	1.0000	0.0417
Sin emoji	434	0.8686	0.1653	0.0288

Tabla 16 Desempeño por subgrupo sobre el conjunto de prueba

9.2 Brechas de paridad

Comparación	Δ F1-macro	Δ FPR
Plataforma X vs Plataforma Facebook	+0.1480	-0.0542
Con jerga salvadoreña vs Sin jerga	+0.1093	+0.1269
Sarcasmo: sí vs Sarcasmo: no	-0.2084	+0.1806
Ironía: sí vs Ironía: no	-0.2974	+0.0367
Contexto político: sí vs Contexto político: no	+0.1077	-0.1338
Con emoji vs Sin emoji	-0.5631	+0.8347

Tabla 17 Diferencias de desempeño entre subgrupos




Figura 10 Brechas de desempeño entre subgrupos del conjunto de prueba

Las barras hacia la derecha señalan subgrupos donde el sistema rinde mejor; hacia la izquierda, donde rinde peor. Las dos barras rojas son las figuras retóricas, y son además las más largas: la ironía abre una brecha de casi treinta puntos de F1-macro, el doble que la brecha entre plataformas.

9.3 Calibración

Una métrica de acierto no dice nada sobre si el sistema sabe cuándo se está equivocando, y eso importa si la salida va a presentarse a un moderador humano.




Figura 11 Confianza declarada frente a acierto observado

La curva del modelo queda por debajo de la diagonal en casi todo el rango: cuando declara un 90 % de confianza acierta menos del 90 %. El error de calibración esperado es de 0.1214, mejor que el 0.1640 del modelo de la etapa anterior pero aún lejos de ser fiable. La implicación práctica es que la confianza que devuelve el prototipo no debe leerse como una probabilidad.

9.4 Interpretación

El sesgo dialectal, que era el hallazgo central de la auditoría, se reduce por primera vez sobre datos reales. La tasa de falsos positivos en textos inofensivos con jerga salvadoreña pasa del 41-45 % de los modelos anteriores al 27.6 % del modelo de esta etapa, y la brecha respecto al español estándar se reduce a la mitad.

Debe decirse con la misma claridad que ese corte tiene 29 casos. Un solo ejemplo mueve la métrica 3.4 puntos. La tendencia es consistente con el resto de las mediciones, pero el corte por sí solo no tiene potencia estadística, y la conclusión sobre equidad dialectal no debería presentarse como definitiva hasta recolectar más ejemplos reales.

Las dos brechas mayores son las figuras retóricas. El F1-macro cae 0.21 puntos ante sarcasmo y 0.30 ante ironía, y la tasa de falsos positivos sube 18 puntos con sarcasmo. Es el sesgo más severo que queda y afecta a un fenómeno muy frecuente en el registro coloquial salvadoreño: un sistema desplegado sobre este dominio sobre-bloquearía la ironía.

La brecha entre plataformas persiste en 0.148 de F1-macro a favor de X. Es un problema de composición del corpus, no de modelado: los textos de Facebook son más largos, con múltiples hilos y sintaxis más compleja, y están peor representados.

El corte con emoji tiene solo dos casos negativos, de modo que su tasa de falsos positivos del 100 % corresponde a dos errores y no admite lectura estadística. Se incluye por transparencia y no como hallazgo.

9.5 Consideraciones éticas del sistema

- El sistema es una herramienta de investigación, no de moderación automatizada. Ninguna decisión que afecte a una persona debería tomarse solo con su salida.
- La calibración es imperfecta: el error de calibración esperado es de 0.1214, y el prototipo devuelve confianzas cercanas al 100 % que no reflejan incertidumbre real. Presentar esas cifras a un moderador humano induciría exceso de confianza.
- Se descartó deliberadamente toda capa de reglas post-hoc. Una regla que solo puede mover predicciones hacia No Tóxico reduce la tasa de falsos positivos por construcción, sin que el modelo haya aprendido nada, y abre una vía de evasión trivial.
- El corpus contiene lenguaje ofensivo y discurso de odio explícito por la naturaleza de la tarea. Los autores están seudonimizados y las URLs de origen quedaron fuera.
- El sistema hereda los sesgos de quienes etiquetaron. El acuerdo entre anotadores es de 0.8095 de F1-macro, y sobre los casos en que los anotadores discrepan el modelo acierta prácticamente al azar. La calidad de la etiqueta es el techo real del problema.

10 Prototipo Funcional

El prototipo consta de una API construida con FastAPI y una interfaz web. La decisión de diseño central es que el endpoint importa la función de

normalización del mismo módulo que preparó el entrenamiento, sin una segunda implementación que pueda divergir. Es la condición para que las métricas de este documento describan lo que ocurre en producción y no otra cosa.

Ruta	Método	Función
/salud	GET	Estado, dispositivo, clases y contrato de inferencia
/clasificar	POST	Un texto: clase, confianza, las cuatro probabilidades y nivel de riesgo
/clasificar-lote	POST	Hasta 64 textos por petición
/	GET	Interfaz web

Tabla 18 Endpoints del prototipo

Entrada	Salida
Qué onda maje, todo bien por allá	No Tóxico
Callate ya, cerote	Lenguaje Ofensivo
Los nicaragüenses son una plaga	Discurso de Odio
Te voy a m4t4r	Amenazas/Violencia
Ya sabés lo que te espera [pistola de agua]	Amenazas/Violencia
gracias, te voy a matar	Amenazas/Violencia

Tabla 19 Comprobación del prototipo en ejecución

La última fila corresponde al caso que evadía el prototipo de la entrega anterior. La interfaz muestra, además de la clase, el desglose de probabilidades y el texto exactamente como lo recibe el modelo tras la normalización, de modo que el comportamiento sea auditable desde la propia pantalla.

11 Impacto Social y Recomendaciones de Política Pública

11.1 El problema en el contexto salvadoreño

El debate público salvadoreño ocurre en buena medida en X y Facebook, y las herramientas de moderación de esas plataformas operan sobre modelos entrenados en español general. Este trabajo documenta con datos lo que hasta ahora era una sospecha razonable: esos modelos no leen bien el registro local.

La medición más concreta es el sesgo dialectal. Los modelos de la etapa anterior marcaban como tóxico entre el 41 % y el 45 % de los textos inofensivos que contenían jerga salvadoreña, frente al 16 % de sus equivalentes en español estándar. Es decir, hablar como se habla en El Salvador multiplicaba por 2.7 la probabilidad de ser silenciado por error. Un sistema con ese comportamiento desplegado a escala penaliza sistemáticamente a los hablantes del registro local.

11.2 Aportes concretos de este trabajo

- Un corpus salvadoreño etiquetado en cuatro niveles de gravedad, con validación entre anotadores, que no existía y que queda disponible para la comunidad investigadora.
- Un léxico de 110 familias con 1,979 variantes de ofuscación documentadas, que es un recurso reutilizable con independencia del modelo.
- Evidencia medida de que el preentrenamiento sobre lenguaje de redes sociales importa más que el tamaño del modelo para esta tarea, lo que abarata sustancialmente cualquier implementación posterior: el modelo final tiene 109 millones de parámetros y se entrena en dos minutos en una tarjeta gráfica de consumo.
- Una metodología de auditoría —batería adversarial, sonda de ofuscación y prueba de evadibilidad— aplicable a cualquier sistema de moderación que se quiera verificar antes de confiar en él.

11.3 Recomendaciones de política pública

Las recomendaciones se ordenan de mayor a menor viabilidad inmediata.

Destinatario	Recomendación	Fundamento en este trabajo
Instituciones públicas con presencia digital	Exigir a cualquier herramienta de moderación que reporte su tasa de falsos positivos desagregada por registro dialectal antes de adoptarla	La brecha medida entre jerga local y español estándar era de 28 puntos porcentuales en los modelos de partida
Universidades y centros de investigación	Priorizar la recolección y el etiquetado de corpus locales por encima de la adopción de modelos cada vez mayores	Un modelo de 109 M superó a uno de 560 M; el cuello de botella medido es el corpus, no la capacidad
Organismos de derechos digitales	Documentar casos de sobre-bloqueo de habla local y usarlos como evidencia ante las plataformas	El sesgo dialectal es medible y reproducible con la metodología de este trabajo
Plataformas y desarrolladores	Publicar auditorías de equidad por variedad lingüística, no solo por idioma	El español de El Salvador se comporta como un dominio distinto del español general
Medios de comunicación y gestores de comunidad	Usar sistemas como este para priorizar la revisión humana, nunca para bloquear automáticamente	El acuerdo entre anotadores humanos es de 0.8095; el modelo no puede ser más fiable que la etiqueta

Destinatario	Recomendación	Fundamento en este trabajo
Formuladores de política educativa	Incorporar alfabetización digital sobre discurso de odio en el currículo, apoyándose en la taxonomía de cuatro niveles	La distinción entre lenguaje ofensivo y discurso de odio es la que más cuesta, también a las personas

Tabla 20 Recomendaciones de política pública

11.4 Lo que este trabajo no resuelve

Un sistema de clasificación no arregla el discurso de odio; como mucho ayuda a medirlo y a priorizar dónde mira una persona. Tres límites deben acompañar cualquier recomendación derivada de este trabajo.

- El modelo no entiende contexto conversacional: evalúa publicaciones aisladas, y buena parte del acoso real es acumulativo y distribuido entre varias publicaciones.
- La ironía y el sarcasmo, que son el registro habitual de buena parte del debate político salvadoreño, siguen siendo el punto débil medido.
- Automatizar la moderación sobre una base de 2,144 ejemplos reales sería imprudente. El sistema está listo como instrumento de investigación y de priorización, no como decisor.

12 Limitaciones

- El corpus real sigue siendo de 2,144 publicaciones de entrenamiento. La meta de 771 ejemplos reales por clase no se ha alcanzado en Discurso de Odio ni en Amenazas/Violencia.
- La sonda dialectal sobre datos reales tiene 29 casos. Cualquier cifra de sesgo calculada sobre ese corte es frágil.
- Los emojis de amenaza no tienen un solo caso real recolectado: toda su cobertura es sintética.
- La sonda dirigida de 204 casos perdió su independencia respecto al modelo de esta etapa, por compartir léxico con el generador.
- La brecha entre plataformas no se resolvió y es estructural del corpus.

- La calibración sigue siendo imperfecta, con un error esperado de 0.1214.
- El techo real del problema es la calidad de la etiqueta: el acuerdo entre anotadores es de 0.8095 de F1-macro, y sobre los casos disputados el mejor modelo de la etapa anterior acertaba el 50 % de las veces.

13 Conclusiones

El sistema alcanza un F1-macro de 0.8656 sobre el conjunto de prueba, con un intervalo de confianza del 95 % de [0.8322, 0.8968], y una validación cruzada de cinco pliegues que promedia 0.8317 ± 0.0246 . La meta de 0.80 se cumple también en el extremo inferior del intervalo, que era el criterio exigente que se fijó al inicio de la etapa.

La mejora respecto a la etapa anterior proviene, en orden de importancia, de tres decisiones. La primera y con diferencia la mayor fue cambiar de familia de modelo: los dos modelos elegidos en la Etapa I resultaron ser los dos peores de una comparación de siete, y sustituirlos por modelos preentrenados sobre lenguaje de redes sociales en español aportó cerca de cuatro puntos. La segunda fue optimizar hiperparámetros, que nunca se había hecho y aportó 0.025. La tercera, más modesta, fue el corpus sintético dirigido usado con el régimen de entrenamiento adecuado.

Igual de útil es dejar constancia de las tres vías que no funcionaron. Escalar el modelo no ayuda: 560 millones de parámetros rinden peor que 109 millones. Extender el vocabulario con tokens de dominio perjudica en todas las configuraciones probadas. Y generar ejemplos sintéticos en familias donde el modelo ya acierta no aporta nada y desplaza la distribución de entrenamiento.

El sesgo dialectal, que motivó buena parte del trabajo, se reduce por primera vez sobre datos reales, aunque el corte que lo mide es demasiado pequeño para considerarlo cerrado. Las figuras retóricas quedan como el sesgo más severo pendiente.

Lo que no cambia es el diagnóstico de fondo: con 2,144 publicaciones reales y un acuerdo entre anotadores de 0.8095, el siguiente salto no saldrá de más arquitectura sino de más datos y mejores etiquetas.

14 Reproducibilidad y Evidencias

14.1 Repositorio

Código fuente, corpus, informes y artefactos de evaluación: <https://github.com/caeher/cde-project-ml-2026>, rama v3.

Los pesos del modelo no se versionan por exceder el límite de tamaño de fichero de la plataforma. Todos los scripts son deterministas con semilla fija y el manifiesto incluye la función resumen SHA-256 de los pesos de referencia.

Sección	Comando
Adecuación del tokenizador	<code>python3 src/audit/analisis_tokenizadores.py</code>
Comparación de arquitecturas	<code>python3 src/v3/bakeoff.py</code>
Construcción del corpus	<code>python3 src/v3/construir_dataset.py</code>
Ablación	<code>python3 src/v3/ablacion.py</code>
Optimización de hiperparámetros	<code>python3 src/v3/hpo.py 20</code>
Validación cruzada	<code>python3 src/v3/validacion_cruzada.py</code>
Modelo final	<code>python3 src/v3/entrenar_final.py</code>
Ensemble	<code>python3 src/v3/ensemble.py</code>
Evaluación completa	<code>python3 src/v3/evaluar.py models/v3/final v3_final</code>
Prototipo	<code>python3 -m uicorn app.api.main:app</code>

Tabla 21 Scripts para reproducir cada sección

14.2 Verificación de integridad

Conjunto	SHA-256 (16 primeros)	¿Modificado en esta etapa?
val.csv	45aabe9744711d74	No
test.csv	5d1284efcc7df20f	No

Tabla 22 Funciones resumen de los conjuntos de evaluación

Ambas coinciden con las de la etapa anterior. Se verificó además que ningún texto del entrenamiento aparece en validación, en prueba ni en la batería adversarial.

15 Glosario

Ablación: Experimento que elimina o modifica un componente del sistema para medir cuánto aportaba.

Ensemble: Combinación de varios modelos cuyas predicciones se promedian, con el fin de reducir la varianza de cualquiera de ellos por separado.

F1-macro: Media no ponderada del F1 de cada clase. Trata las cuatro clases por igual, por lo que penaliza a un modelo que acierte solo en la clase mayoritaria.

Fertilidad del tokenizador: Número medio de subtokens en que se divide una palabra. Cuanto mayor, más fragmentado queda el texto.

FPR: Tasa de falsos positivos: proporción de contenido inofensivo clasificado como tóxico.

FNR: Tasa de falsos negativos: proporción de contenido tóxico que el sistema deja pasar.

Intervalo bootstrap: Rango de valores plausibles de una métrica, obtenido remuestreando el conjunto de prueba con reemplazo.

Leetspeak: Sustitución de letras por dígitos o símbolos de forma similar («m4t4r» por «matar»), usada para evadir filtros automáticos.

Ofuscación: Deformación deliberada de una palabra para que un filtro no la reconozca pero una persona sí.

Optuna: Biblioteca de optimización de hiperparámetros que propone configuraciones guiada por los resultados anteriores.

Prueba de McNemar: Prueba estadística que compara dos clasificadores sobre las mismas instancias, contando en cuántas acierta uno y falla el otro.

Train/serve skew: Divergencia entre el preprocesamiento del entrenamiento y el de producción, que invalida las métricas del informe.

Validación cruzada estratificada: Procedimiento que divide los datos en pliegues conservando la proporción de clases, entrena sobre unos y evalúa sobre el restante, rotando.

Voto blando: Forma de ensemble que promedia las probabilidades de los modelos en lugar de contar sus votos discretos.

16 Anexos

16.1 Anexo A: Informe de auditoría de la entrega anterior

Reejecución independiente de los cuatro checkpoints entregados, con tabla de contraste entre cifra publicada y cifra reproducida, lista de errores con

su evidencia aritmética y prueba de evadibilidad del filtro de reglas. Archivo: reports/9-12-2026/Informe_Auditoria_Entrega_2v.pdf.

16.2 Anexo B: Informe técnico de resultados de la Etapa II

Detalle de las veinte pruebas de optimización, las nueve variantes de ablación por arquitectura y las tablas completas de la batería adversarial y la sonda dirigida. Archivo: reports/9-12-2026/Informe_V3_Resultados_Etapa3.pdf.

16.3 Anexo C: Artefactos de evaluación

Logits, predicciones por instancia, resultados de las pruebas pareadas y de la prueba de evadibilidad, en reports/v3_resultados/ y reports/v3_arquitectura/ del repositorio.