

Auditoría de la entrega 2v

Índice general

Auditoría de la entrega 2v — reejecución independiente de los modelos	1
0. Condiciones de la reejecución	1
1. Resultado en una línea	2
2. Tabla de contraste: publicado contra reproducido	2
3. Errores encontrados en el informe de Cristian	4
4. Errores encontrados en el informe de Julio	6
5. Rendimiento verificado de los cuatro modelos	9
6. Juicio metodológico	13
7. Correcciones pendientes	14
8. Recomendación para la tesina	16
Anexo. Artefactos generados	17

Auditoría de la entrega 2v — reejecución independiente de los modelos

Autor: Willian Alexander Chávez Servellón **Fecha:** 12 de septiembre de 2026 **Alcance:** los dos informes de la entrega 2v, sus ZIP anidados y los pesos entregados. **Método:** no se aceptó ninguna cifra publicada. Se abrieron los ZIP, se cargaron los cuatro checkpoints y se corrió el *forward pass* sobre `test.csv`, `val.csv` y la batería adversarial.

0. Condiciones de la reejecución

Entorno	WSL2 · Python 3.10.12 · PyTorch 2.8.0+cu128 · transformers 5.17.0 · GPU RTX 4060
Contrato	max_length = 128, columna texto_modelo, semilla 42
Scripts	src/audit/reproducir_2v.py, metricas_2v.py, bateria_2v.py, pipeline_julio.py, sonda_ofuscacion_emoji.py
Artefactos	reports/v2_auditoria/ (logits, predicciones, manifiesto de hashes)

Checkpoints auditados, con el SHA-256 de `model.safetensors`:

Alias	Autor	Ruta	SHA-256 (12 primeros)
mbert_v1	Cristian	Pesos del modelo/mbert-sv-audit.zip	b2de91405b7c
mbert_b2	Cristian	2v/.../metricas-proyecto-ml/models/mbert-sv	7a3ab6c53223
xlmr_v1	Julio	Para modelo XLMR/.../modelo_entrenado	574a513b7f9e
xlmr_mit	Julio	2v/.../prototipoV2/.../modelo_mitigado	b0cd9cca4ce8

Verificación previa de los datos. Los CSV que usó Cristian son byte a byte los que se le entregaron: train.csv, val.csv, test.csv, metadata.json y lexicon_emojis.csv tienen hash idéntico al de data/dataset_b2/. Su train es de 3,293 filas. Ese punto queda cerrado. Julio, en cambio, **no usó el dataset B2**: su train_mitigado.csv tiene 2,165 filas (el train v1 de 2,144 más 21 añadidas). Volveré sobre esas 21 en la sección 4.1.

1. Resultado en una línea

De las dos entregas, **una reproduce todas sus cifras y la otra no reproduce ninguna de las tres que declara como resultado.**

Cristian publicó 0.7610 de F1-macro y la reejecución da 0.7610. Todas sus tablas cuadran al cuarto decimal. Sus errores son de redacción, no de medición: cuatro, uno de los cuales invierte una conclusión.

Julio publicó accuracy 80.22 %, recall de Odio 81.05 % y recall de Amenazas 80.72 % sobre un conjunto que llama «N = 1050». Ese conjunto no existe en el proyecto, sus propias salidas de notebook muestran soporte 460, y **ninguna combinación de umbrales sobre los pesos que entregó reproduce esa terna**. Además su modelo fue entrenado con 21 textos del conjunto de prueba, y su filtro de reglas se desactiva escribiendo «gracias».

2. Tabla de contraste: publicado contra reproducido

2.1 Cristian — mBERT B2 (checkpoint-1644)

Cifra	Publicado	Reproducido	Δ	Estado
F1-macro test	0.7610	0.7610	0.0000	reproducible
Accuracy test	0.7674	0.7674	0.0000	reproducible
IC bootstrap 95 %	[0.7179, 0.7981]	[0.7172, 0.7983]	± 0.0007	reproducible (semilla distinta)
ECE	0.1640	0.1640	0.0000	reproducible
F1-macro validación	0.756	0.7560	0.0000	reproducible
F1 No Tóxico	0.7837	0.7837	0.0000	reproducible
F1 Lenguaje Ofensivo	0.7925	0.7925	0.0000	reproducible
F1 Discurso de Odio	0.7330	0.7330	0.0000	reproducible
F1 Amenazas/Violencia	0.7349	0.7349	0.0000	reproducible
Plataforma X	0.8190	0.8190	0.0000	reproducible
Plataforma Facebook	0.6648	0.6648	0.0000	reproducible

Cifra	Publicado	Reproducido	Δ	Estado
FPR No Tóxico con jerga	0.4138	0.4138 (12/29)	0.0000	reproducible
FPR No Tóxico sin jerga	0.1596	0.1596 (15/94)	0.0000	reproducible
Batería 75 casos, B2	64/75	64/75	0	reproducible
Batería 75 casos, v1	45/75	45/75	0	reproducible
Batería 144 casos, B2	120/144	120/144	0	reproducible (ver 3.2)
Batería 144 casos, v1	69/144	69/144	0	reproducible (ver 3.2)
Grupo C, amenazas ofuscadas	11/11, FN = 0	11/11, FN = 0	0	reproducible
Grupo B, emojis	16/18	16/18	0	reproducible
Grupo A, ofuscación	12/20	12/20	0	reproducible
Brecha FPR dialectal (D – E)	0.0714	0.0714	0.0000	reproducible
McNemar vs XLM-R v1	b = 26, c = 44, p = 0.041391	b = 26, c = 44, p = 0.041391	0	reproducible
Baseline LinearSVC	0.7482	0.7482	0.0000	reproducible
Baseline LogisticRegression	0.7354	0.7354	0.0000	reproducible
Baseline MultinomialNB	0.6932	0.6932	0.0000	reproducible
Piso clase mayoritaria	0.1284	0.1284	0.0000	reproducible

26 de 26 cifras reproducibles. Es la primera entrega del proyecto en la que ocurre.

2.2 Julio — Prototipo V2 (modelo_mitigado)

Cifra	Publicado	Reproducido	Estado
FPR jerga, baseline	44.83 %	44.83 % (13/29, xlmr_v1)	reproducible
FPR «sistema mitigado»	14.63 %	14.63 % pero no es FPR de jerga : es el FPR binario sobre los 123 No Tóxico completos	no comparable
FPR de jerga del sistema mitigado	no reportado	31.03 % (9/29)	—
Recall Discurso de Odio	81.05 %	82.11 % (78/95) con sus umbrales · 80.00 % en argmax	no reproducible
Recall Amenazas/Violencia	80.72 %	81.93 % (68/83)	no reproducible

Cifra	Publicado	Reproducido	Estado
Accuracy global multiclase	80.22 %	78.70 % (362/460) con sus umbrales · 78.91 % en argmax	no reproducible
Conjunto de evaluación	N = 1050	n = 460 (el test del proyecto)	cifra inventada
Baseline accuracy	81.09 %	80.65 % (371/460)	no reproducible
Baseline recall	77.38 %	78.31 % (65/83)	no reproducible
Amenazas			
Baseline recall Odio	82.11 %	82.11 %	reproducible
F1-macro del sistema	no reportado	0.7887 (argmax) · 0.7837 (pipeline completo)	—
F1-macro del baseline XLM-R v1	no reportado	0.8058	—

3 de 11 cifras reproducibles. Las tres que declara como resultado del trabajo — accuracy 80.22 %, recall 81.05 % y 80.72 % — no salen de los pesos que entregó.

Para descartar que fuera un problema de configuración por mi parte, hice una búsqueda exhaustiva: recorrí las 884,736 combinaciones de umbrales (T_1 , T_2 , T_3) en una rejilla de paso 0.01 sobre [0.00, 0.95] aplicadas a los logits del modelo entregado. **Ninguna** reproduce simultáneamente 369/460 aciertos, 77/95 de recall en Odio y 67/83 en Amenazas. Sus umbrales publicados (0.45 / 0.36 / 0.48) dan 362, 78 y 68.

3. Errores encontrados en el informe de Cristian

Cuatro. Los ordeno por gravedad. Ninguno afecta a las mediciones; los cuatro son de transcripción o de lectura del dato.

3.1 Conclusión invertida sobre McNemar — crítico

El hallazgo 3 dice:

«La prueba de McNemar confirma superioridad significativa de mBERT B2 frente a MultinomialNB y frente a XLM-RoBERTa v1 ($\alpha = 0,05$)»

La prueba reproducida da $b = 26$, $c = 44$, $p = 0.041391$. En la convención de la propia tabla, b son los aciertos exclusivos de mBERT y c los de XLM-R. Con $c > b$ el signo va **a favor de XLM-R**. El texto de la sección 6 lo dice correctamente («con XLM-R acertando más instancias en este test»); la conclusión lo dice al revés.

La lectura correcta es incómoda pero hay que escribirla: al adoptar B2, mBERT pasó de estar empatado con XLM-R ($p = 0.20$ con el v1) a estar **significativamente por debajo** ($p = 0.041$). El Δ F1-macro lo confirma:

XLM-R v1 – mBERT v1 : +0.0281 IC95 [-0.0075, +0.0625] incluye 0 -> empate
XLM-R v1 – mBERT B2 : +0.0448 IC95 [+0.0080, +0.0807] NO incluye 0 -> XLM-R superior

3.2 Las dos columnas de la tabla de familias vienen de dos baterías distintas — crítico

Esto no se había detectado antes y es más grave que el error de celda que se sospechaba.

En su ZIP hay un fichero `data/processed/test_adversarial_144.csv` que Cristian **generó él mismo** con `scripts/build_adversarial_144.py`. Tiene los mismos siete grupos y los mismos tamaños que la batería entregada, pero **no es la misma batería**:

	Batería entregada	Batería de Cristian
Textos coincidentes	—	78 de 144
Grupo F, etiquetas esperadas	$30 \times \text{clase 0} + 4 \times \text{clase 1}$	$34 \times \text{clase 0}$
Grupo G, etiquetas esperadas	19/4/6/6	20/2/2/11

Corrí ambas. Sobre **su** batería, sus cifras salen exactas (mBERT B2 = 120/144, v1 = 69/144). Sobre la **entregada**, mBERT B2 también da 120/144 pero con F y G intercambiados (F = 30/34, G = 26/35 en lugar de F = 26/34, G = 30/35), y el v1 da **74/144**, no 69.

El problema es que su columna de XLM-R sí está medida sobre la batería **entregada**: los valores A 17, B 6, C 5, D 6/14 de FPR, E 0/12 y el global 74/144 coinciden exactamente con mi reejecución sobre la batería oficial. Es decir, **la tabla compara mBERT medido en una batería contra XLM-R medido en otra**.

Y dentro de esa misma fila hay además el error de celda que ya se sospechaba: el grupo F de XLM-R dice **26/34** de falsos positivos. El valor correcto es **20/34** en la batería entregada y **14/34** en la suya. El 26 es el número de *aciertos de mBERT* en esa misma fila, copiado de una columna a la otra.

Añado que la tabla mezcla dos magnitudes sin decirlo: A, B, C y G son aciertos; D, E y F son falsos positivos. Sumada tal como está escrita da 78, no 120.

3.3 El sesgo dialectal no mejoró en datos reales — crítico

El hallazgo 2 dice que B2 «reduce el sesgo dialectal (FPR gap 0.07 vs. 0.86)». El hallazgo 5, tres párrafos después, dice que «la sonda dialectal muestra FPR elevado en No Tóxico con jerga local (41 % vs. 16 %)». Los dos son ciertos y hablan de cosas distintas:

	mBERT v1	mBERT B2
Brecha D – E en la batería sintética	0.8571	0.0714
FPR con jerga en test.csv (n = 29)	0.4138	0.4138
FPR sin jerga en test.csv (n = 94)	0.1596	0.1596

En datos reales la brecha **no se movió ni un punto**. Los grupos D y E de la batería salen de plantillas emparentadas con las que generaron los sintéticos de B2; ahí la mejora es casi total. En el test real, donde no hay parentesco de plantilla, no hay mejora.

Dos matices a favor de Cristian. Primero: el grupo F (falsos amigos dialectales) es el más independiente de las plantillas y ahí la mejora sí es genuina — 4/30 falsos positivos frente a 17/30 del v1. Segundo: en mi sonda dirigida, construida hoy y que ningún modelo pudo haber visto, la brecha de B2 es **−0.10** frente a **+0.40** del v1 (sección 5.4). La mejora de representación existe; lo que no existe es en el test real, y es eso lo que hay que declarar.

3.4 Errores menores

#	Dónde	Qué dice	Qué debe decir
a	Texto de baselines, p. 8	LinearSVC 0,765 · LogReg 0,758 · MNB 0,648	0.7482 · 0.7354 · 0.6932 (la tabla de la misma página ya está bien)
b	Tabla de trazabilidad	checkpoint-1072 en las tres filas	el oficial es checkpoint-1644; solo la fila histórica de 0.7777 es 1072
c	Tabla de trazabilidad, fila 0.7715	atribuida a mbert-sv-b2/train_metrics.json	0.7715 es la validación del v1 ; la de B2 es 0.7560 (verificada)
d	Capítulo 8	tres tablas con la nota «Datos no disponibles»	Jaccard LIME-SHAP nulo y pesos globales LIME no exportados: el capítulo no tiene contenido

Sobre (d): el capítulo de interpretabilidad ocupa página y media y las tres tablas están vacías. Conviene reducirlo a una nota metodológica de un párrafo en limitaciones.

4. Errores encontrados en el informe de Julio

Son de otra naturaleza. No son de transcripción: afectan a la validez de lo medido.

4.1 Contaminación del conjunto de prueba — crítico, invalida el resultado

Es el hallazgo central de esta auditoría. La cadena está documentada en su propio `estadisticas3.ipynb`:

1. **Celda 5.** Evalúa el modelo baseline sobre `test.csv` y aísla los falsos positivos.
2. **Celda 7.** Los exporta a `falsos_positivos_diagnostico.csv` — 28 textos, **los 28 del test**.
3. **Celda 8.** Construye `train_mitigado.csv` reinyectando esos textos con `label = 0` más variantes con la jerga sustituida.
4. **Celda 24.** Reentrena el modelo sobre `train_mitigado.csv`.
5. **Celdas 25-28.** Mide el FPR sobre `test.csv` y reporta que bajó.

Verificación aritmética:

```
falsos_positivos_diagnostico.csv : 28 filas
n test.csv = 28          <- el 100 %
n val.csv   = 0
n train.csv = 0
```

```
train_mitigado.csv : 2165 filas (train v1 = 2144, añadidas = 21)
filas presentes literalmente en test.csv = 21
```

21 textos del conjunto de prueba están en su conjunto de entrenamiento, etiquetados como No Tóxico, y son exactamente los textos sobre los que después mide la mejora del FPR. El modelo no aprendió a no equivocarse: memorizó las respuestas de los casos en los que se equivocaba. Cualquier cifra de FPR del modelo `mitigado` sobre `test.csv` está inflada por construcción, y con ella el 14.63 %.

4.2 La comparación 44.83 % → 14.63 % mide dos cosas distintas — crítico

Reproduce los dos números y los dos son correctos por separado. El problema es que no son la misma métrica:

	Qué es	Población	n	Modelo
44.83 %	FPR de No Tóxico con jerga	subconjunto con $n_{\text{jerga}} > 0$	29	xlmr_v1
14.63 %	FPR binario sobre todos los No Tóxico	todos los negativos del test	123	xlmr_mit

La figura 2 del informe los pone como dos barras del mismo gráfico bajo el rótulo «FPR en frases con jerga regional». Comparadas sobre la misma población y sobre el mismo test, las cifras reales son:

	FPR jerga (n = 29)	FPR sin jerga (n = 94)	FPR binario (n = 123)
xlmr_v1 (baseline)	0.4483	0.1596	0.2276
xlmr_mit (mitigado)	0.3103	0.0957	0.1463

La mejora real en jerga es de 44.83 % a **31.03 %**, no a 14.63 %. Y esos 13.8 puntos siguen contaminados por lo de 4.1.

4.3 El conjunto «N = 1050» no existe — crítico

El informe declara los resultados «en el conjunto de validación dialectal salvadoreño (N = 1050)». Las particiones del proyecto son 2,144 / 3,293 (train), 459 (val) y 460 (test). No hay ningún conjunto de 1,050, no está entregado y no se documenta cómo se construiría.

Además **sus propias salidas lo contradicen**: el `classification_report` de la celda 28, que es de donde salen las tres cifras publicadas, imprime soporte 123 / 159 / 95 / 83 y total **460**. Las métricas son del test del proyecto, no de un conjunto de 1,050.

Es la reincidencia de un patrón: en el informe de agosto la figura 1 rotulaba el conjunto de evaluación como «N = 3063» (el corpus completo) cuando la tabla de al lado decía $n = 460$.

4.4 No reporta F1-macro, que es la métrica del proyecto — crítico

El informe da accuracy y dos recalls sueltos. No aparece el F1-macro en ninguna página. Su propio notebook **sí lo calcula**: la celda 28 imprime `macro avg ... 0.8009`. Se omitió del informe.

Calculado sobre los pesos entregados y el test real:

Configuración	F1-macro	Accuracy
xlmr_v1 (baseline de agosto)	0.8058	0.8065
xlmr_mit, nivel 1 (argmax)	0.7887	0.7891
xlmr_mit, nivel 2 (+ umbrales)	0.7876	0.7870
xlmr_mit, nivel 3 (+ regex)	0.7837	0.7826

El Prototipo V2 es peor que el modelo de agosto en la métrica principal, y cada capa de mitigación lo empeora un poco más. La caída total es de 0.0221. Esto no se deduce de ningún número del informe porque el informe no publica la métrica en la que ocurre.

4.5 El filtro regex no hace lo que dice — alto

Medido sobre test.csv: el filtro se activa en **2 textos de 460**, y el FPR es **idéntico** antes y después (0.1463 en los tres niveles). La reducción del FPR que el informe atribuye al pipeline de mitigación viene enteramente del reentrenamiento contaminado. Las capas 2, 3 y 4 no aportan nada positivo y restan 0.005 de F1-macro.

4.6 Prueba de evadibilidad — alto

Pedida explícitamente. Tomé 100 casos de amenaza (11 del grupo C, 6 del grupo G y las 83 amenazas reales de test.csv), les antepuse cada uno de los seis marcadores afectivos del filtro y los pasé por el pipeline completo.

Prefijo	Amenazas clasificadas como No Tóxico	Δ vs. sin prefijo
(ninguno)	1 / 100	—
mi hermano,	21 / 100	+20
gracias,	20 / 100	+19
te quiero pero	20 / 100	+19
qué onda,	19 / 100	+18
todo bien,	17 / 100	+16
buena onda,	17 / 100	+16

Una de cada cinco amenazas se neutraliza anteponiendo una palabra. Ejemplos reales de la salida:

gracias, Te voy a dar piso	-> No Tóxico
gracias, Ya sabés lo que te espera :ataúd:	-> No Tóxico
gracias, Te voy a buscar mañana :cuchillo_de_cocina:	-> No Tóxico
gracias, Aquí los linchamos	-> No Tóxico
gracias, Otro malparido menos	-> No Tóxico

El mecanismo es de dos pasos: el prefijo afectivo empuja la predicción de Amenazas a Ofensivo, y entonces el filtro —que solo actúa sobre Ofensivo— la manda a No Tóxico. Sin el filtro serían 8 de 100; con él, 20. **La capa de mitigación multiplica por 2.5 la evadibilidad del sistema.**

El informe reconoce el problema en su sección 4.2 con el ejemplo «Gracias por arruinarme el día, cerote», y aun así propone el pipeline como solución de producción.

4.7 Errores menores y observaciones

#	Qué	Detalle
a	Cifras del baseline arrastradas	81.09 % y 77.38 % vienen del informe de agosto, ya señalados como incorrectos el 1 de septiembre. Los verificados son 80.65 % y 78.31 %
b	Baseline internamente inconsistente	La tabla por clase de agosto promedia 0.8054, no el 0.8100 declarado. Su matriz de confusión suma 371 aciertos, o sea 0.8065, no 0.8109

#	Qué	Detalle
c	El informe lista 5 patrones regex	El config_umbrales.json tiene 6 : falta \bbuena onda\b
d	Ajuste y evaluación sobre el mismo conjunto	Dice que los umbrales se optimizaron «sobre validación» y reporta «en el conjunto de validación dialectal». Las celdas 21-28 son una búsqueda manual de umbrales sobre el test , iterada hasta que los dos recalls superaron el 80 %
e	Regla de decisión mal documentada	El informe presenta los umbrales como una tabla sin orden. En el código es una cascada AV → DO → LO → NT, y el 0.00 de No Tóxico nunca se evalúa: es el else final. El informe no lo dice
f	inferencia.py no implementa el pipeline	Lo único ejecutable que entregó hace argmax puro: sin umbrales, sin regex. El pipeline de cuatro niveles solo existe dentro de los notebooks
g	v_2/ duplica modelo_mitigado/	Byte a byte (md5 8f87e8a7...). 1.1 GB repetidos en la entrega
h	Falta trazabilidad	No hay training_args.bin, train_metrics.json, test_metrics.json ni manifiesto. Cristian sí los entrega
i	id2label	Corregido. Trae los cuatro nombres reales. El pendiente de agosto queda cerrado
j	Registro impreciso	«en producción», «desplegada», «Sistema Mitigado v1.4». No hay nada desplegado

5. Rendimiento verificado de los cuatro modelos

Todo lo que sigue son mediciones propias sobre test.csv (n = 460).

5.1 Globales

	mBERT v1	mBERT B2	XLNet v1	XLNet mit.
F1-macro	0.7777	0.7610	0.8058	0.7887
Accuracy	0.7826	0.7674	0.8065	0.7891

	mBERT v1	mBERT B2	XLM-R v1	XLM-R mit.
Aciertos	360/460	353/460	371/460	363/460
ECE	0.1570	0.1640	0.0871	0.0970
Log-loss	0.8721	0.8328	0.6350	0.6635
IC 95 % bootstrap	[0.7363, 0.8144]	[0.7172, 0.7983]	[0.7665, 0.8420]	[0.7486, 0.8257]

Ninguno alcanza la meta de 0.80 con holgura. XLM-R v1 la roza en el punto estimado (0.8058) pero el extremo inferior del intervalo está en 0.7665: **no se puede afirmar que el proyecto cumple la meta**. Hay que escribirlo así.

5.2 Por clase (F1)

Clase	Soporte	mBERT v1	mBERT B2	XLM-R v1	XLM-R mit.
No Tóxico	123	0.8136	0.7837	0.8155	0.8502
Lenguaje Ofensivo	159	0.7951	0.7925	0.8061	0.7677
Discurso de Odio	95	0.7461	0.7330	0.8041	0.7415
Amenazas/Violencia	83	0.7561	0.7349	0.7975	0.7953

5.3 Matrices de confusión (fila = real, columna = predicho)

mBERT B2					XLM-R v1					XLM-R mitigado				
	NT	LO	DO	AV		NT	LO	DO	AV		NT	LO	DO	AV
NT	96	16	6	5	NT	95	16	7	5	NT	105	6	8	4
LO	11	126	13	9	LO	9	133	8	9	LO	10	114	23	12
DO	10	7	70	8	DO	5	11	78	1	DO	8	7	76	4
AV	5	10	7	61	AV	1	11	6	65	AV	1	11	3	68

El mitigado de Julio gana 10 aciertos en No Tóxico (105 vs 95) y pierde 19 en Ofensivo (114 vs 133), la mayoría a Discurso de Odio. Es el efecto esperado de subir el recall de Odio bajando su umbral a 0.36: se compra recall en Odio con precisión en Ofensivo.

5.4 Sonda dirigida de ofuscación y emojis — 204 casos nuevos

Construí una sonda aparte, hoy, con 204 casos que **ningún modelo pudo haber visto ni en entrenamiento ni en la batería de 144**. Cubre lo que pediste: groserías disfrazadas con *, @, #, sustitución de vocales por dígitos, amenazas de muerte literales y ofuscadas, eufemismos salvadoreños, y emojis. Con el normalizador del contrato aplicado.

Familia	n	mBERT v1	mBERT B2	XLM-R v1	XLM-R mit.
1. Ofuscación de groserías	66	52	45	59	37
2. Amenazas de muerte	72	23	61	26	39
3. Emoji de amenaza ([pistola de agua][cuchillo de cocina][ataúd][calavera][lápida][bomba])	12	0	12	0	0

Familia	n	mBERT v1	mBERT B2	XLM-R v1	XLM-R mit.
4. Emoji de odio ([mono][jabón][cara de cerdo][ballena])	4	2	4	4	4
5. Emoji inofensivo ([corazón rojo][cara llorando de risa][cañón de confeti][manos en oración])	16	3	16	5	8
6. Par mínimo de emoji	14	4	14	2	2
7. Jerga salvadoreña inofensiva	10	2	8	2	3
8. Control en español estándar	10	6	7	7	8
GLOBAL	204	92	167	105	101

mBERT B2 gana por 62 puntos sobre el segundo. Y gana justo donde importa para moderación:

- **Amenazas ofuscadas:** 61/72 contra 23/72 del v1. La versión v1 clasificaba «Te voy a m4t4r» como Ofensivo; B2 la clasifica como Amenaza. Los cuatro modelos aciertan la forma literal; solo B2 aguanta el disfraz.
- **Emojis de amenaza:** 12/12 contra **0/12 de los otros tres**. Ni XLM-R v1 ni el mitigado de Julio reconocen «Te espero en la esquina [pistola de agua]» como amenaza: los dos dicen Ofensivo o No Tóxico.
- **Emoji inofensivo:** 16/16. Los demás siguen disparando toxicidad ante un [corazón rojo] o un [cañón de confeti] en texto amable — el atajo «hay emoji, es ofensivo» que motivó B2 sigue vivo en los otros tres.

Tasa de fuga por tipo de disfraz, sobre las familias 1 y 2 (porcentaje de casos en que el disfraz hace caer la predicción por debajo de la clase esperada; más bajo es mejor):

Disfraz	Ejemplo	mBERT v1	mBERT B2	XLM-R v1	XLM-R mit.
asterisco	p**a	66.7 %	16.7 %	41.7 %	33.3 %
arroba	put@	41.7 %	0.0 %	33.3 %	25.0 %
numeral	pend#j#	50.0 %	33.3 %	16.7 %	25.0 %
leet vocales	m4t4r, m13rda	41.7 %	8.3 %	41.7 %	16.7 %
leet consonantes	pu7a, mier6a	50.0 %	8.3 %	33.3 %	16.7 %
espaciado	p u t a	58.3 %	8.3 %	41.7 %	8.3 %
punto	p.u.t.a	50.0 %	16.7 %	41.7 %	33.3 %
eufemismo	«dar piso», «dar cuello»	50.0 %	33.3 %	66.7 %	50.0 %

El disfraz más eficaz contra todos los modelos sigue siendo el **eufemismo salvadoreño**: «te voy

a dar piso», «lo van a poner a dormir». No es ofuscación ortográfica, es conocimiento cultural, y ahí ni siquiera B2 pasa de dos tercios.

Brecha dialectal en la sonda (familia 7 jerga contra familia 8 su equivalente estándar):

	FPR jerga	FPR control	Brecha
mBERT v1	0.80	0.40	+0.40
mBERT B2	0.20	0.30	-0.10
XLM-R v1	0.80	0.30	+0.50
XLM-R mitigado	0.70	0.20	+0.50

Sobre casos nuevos, B2 es el único que no penaliza la jerga; de hecho la brecha se invierte. El pipeline de Julio deja la brecha exactamente donde estaba en el v1.

5.5 Un apunte sobre el normalizador — responsabilidad mía

Al correr la sonda con emoji crudo y con emoji normalizado salió una diferencia grande:

	Emoji crudo	Normalizado	Δ
mBERT B2	31/46	46/46	+15
XLM-R v1	24/46	11/46	-13
XLM-R mit.	24/46	14/46	-10

Dos cosas. La primera: **si la API no aplica `normalize_for_model`, mBERT B2 pierde un tercio de su ventaja en emojis**. La demojización no es cosmética, es parte del modelo. Hay que blindarlo en el endpoint.

La segunda es un defecto del léxico que mantengo yo: la librería emoji traduce [pistola de agua] como `:pistola_de_agua:`, no como `:pistola:`. Los modelos aprenden sobre «pistola de agua». No ha impedido que B2 acierte los 12 casos, pero es un mapeo semánticamente equivocado en un emoji que el proyecto documenta como vehículo de amenaza. Corregir el mapeo en `src/features/normalization.py` y reentrenar.

5.6 Comparación pareada de los cuatro

McNemar exacto, mismas 460 instancias:

A	B	b (solo A)	c (solo B)	p	Favorece
mBERT v1	mBERT B2	24	17	0.3489	v1, n.s.
mBERT v1	XLM-R v1	25	36	0.2000	XLM-R, n.s.
mBERT B2	XLM-R v1	26	44	0.0414	XLM-R, significativo
XLM-R v1	XLM-R mit.	37	29	0.3891	v1, n.s.
mBERT B2	XLM-R mit.	33	43	0.3019	mitigado, n.s.

Solo una comparación de seis es significativa, y es la que contradice la conclusión 3 de Cristian.

6. Juicio metodológico

6.1 ¿Cuánto de la mejora de B2 es memorización de plantillas?

Es la pregunta legítima y la respuesta es: una parte, no toda.

Evidencia	Independencia de las plantillas	Mejora B2 vs v1
Grupos D + E de la batería	baja — plantillas emparentadas	2/14 → 13/14
test.csv real, sonda de jerga	total	0.4138 → 0.4138 (nada)
Grupo F, falsos amigos	alta	17/34 → 30/34
Sonda dirigida de hoy	total	92/204 → 167/204

Los grupos D y E están inflados: ahí el modelo reconoce plantillas. El test real no muestra mejora. Pero el grupo F y sobre todo la sonda nueva, escrita después de que el modelo se entrenara y sin reutilizar ninguna plantilla del generador, muestran una mejora grande y real.

Mi lectura: **la mejora de representación existe y es sustancial en robustez, pero la sonda de jerga del test real es demasiado pequeña (n = 29) para detectarla.** Doce falsos positivos de veintinueve; un solo caso mueve la métrica 3.4 puntos. No se puede concluir ni que mejoró ni que no mejoró en datos reales con ese tamaño. Lo honesto en la tesina es declarar el tamaño y decir que el corte no tiene potencia estadística.

6.2 Solape entre la batería y el entrenamiento — sigue sin corregirse

Hay **7 textos** de la batería adversarial que aparecen literalmente en el train de B2:

```
te voy a matar          te voy a m4t4r          te voy a m*tar
te voy a dar piso       te espero afuera :cuchillo_de_cocina:
te espero afuera :pistola_de_agua:
ese cerote es mi mejor amigo desde la escuela
```

Son las mismas 7 que se detectaron en agosto. Cuatro están en el grupo C, que es justo el grupo donde B2 saca 11/11. **La batería de 144 no es un conjunto limpio de generalización** y hay que declararlo cuando se reporte el 120/144. Es responsabilidad mía corregirlo: o se quitan esas 7 filas de la batería, o se quitan del train.

6.3 ¿Son comparables los dos enfoques?

No, y conviene decir por qué en lugar de ponerlos en la misma tabla.

	Cristian	Julio
Qué cambió	los datos de entrenamiento	reglas sobre la salida
Dónde vive la mejora	en la representación del modelo	en una capa externa
¿Reproducible?	sí, 26/26 cifras	no, 3/11
¿Contaminado?	no, hashes verificados	sí, 21 textos del test
¿Evadible?	como cualquier clasificador	sí, con una palabra
Costo en F1-macro	−0.0167 declarado	−0.0221 no declarado
¿Mejora la métrica del proyecto?	no, y lo dice	no, y no lo dice

El de Cristian es un experimento de aprendizaje automático. El de Julio es ingeniería de reglas, que sería una contribución perfectamente legítima si estuviera medida sobre un conjunto limpio y comparada con la métrica del proyecto. No lo está.

7. Correcciones pendientes

Cristian

#	Tarea	Severidad
1	Corregir el hallazgo 3: McNemar favorece a XLM-R , no a mBERT B2. Declarar que B2 pierde el empate estadístico	Crítica
2	Rehacer la tabla de familias con una sola batería , la entregada. Hoy compara mBERT en su batería contra XLM-R en la oficial	Crítica
3	Resolver la contradicción entre los hallazgos 2 y 5: la mejora dialectal se observa en la batería y no en el test real; declarar además que $n = 29$ no da potencia	Crítica
4	Corregir la celda F de XLM-R: 20/34 en la batería entregada, no 26/34	Alta
5	Etiquetar la magnitud de cada columna de la tabla de familias (aciertos vs. falsos positivos)	Alta
6	Actualizar el texto de los baselines TF-IDF a 0.7482 / 0.7354 / 0.6932	Media
7	Corregir la columna de checkpoint (1644) y la fila de 0.7715 en la tabla de trazabilidad	Media
8	Retirar el capítulo de interpretabilidad o reducirlo a una nota en limitaciones	Media

Julio

#	Tarea	Severidad
1	Reentrenar desde cero sin los 21 textos del test. El modelo_mitigado actual no es utilizable: sus métricas sobre test.csv están contaminadas	Crítica
2	Reportar F1-macro sobre test.csv, con y sin pipeline. Su propio notebook ya lo calcula	Crítica

#	Tarea	Severidad
3	Retirar «N = 1050». Las cifras son sobre n = 460 según su propio classification_report	Crítica
4	Rehacer la comparación de FPR sobre la misma población : jerga contra jerga (44.83 % → 31.03 %), no jerga contra todos	Crítica
5	Separar el conjunto de ajuste de umbrales del de evaluación. Las celdas 21-28 iteran umbrales sobre el test	Crítica
6	Retirar el filtro regex o documentarlo como vulnerabilidad: multiplica por 2.5 la evadibilidad y no mejora el FPR	Alta
7	Corregir el baseline: accuracy 0.8065 y recall Amenazas 0.7831	Alta
8	Especificar la regla de decisión: cascada AV → DO → LO → NT; el 0.00 es el else, no un umbral	Alta
9	Documentar los 6 patrones regex, no 5	Media
10	Reentrenar con data/dataset_b2/ y los pesos [0.9198, 0.9376, 0.9720, 1.2233]. Sigue usando el train v1	Media
11	Hacer que inferencia.py implemente el pipeline que describe el informe	Media
12	Entregar trazabilidad: training_args, métricas en JSON, manifiesto de hashes	Media
13	Borrar v_2/, duplicado exacto de modelo_mitigado/	Baja
14	Reencuadrar «producción / desplegado» como prototipo experimental	Baja

Willian (mías)

#	Tarea	Severidad
1	Quitar las 7 filas solapadas entre la batería adversarial y el train de B2	Alta

#	Tarea	Severidad
2	Corregir el mapeo [pistola de agua] → :pistola_de_agua: en normalization.py	Alta
3	Ampliar la sonda dialectal del test: n = 29 no da potencia para medir el sesgo	Alta
4	Incorporar la sonda de 204 casos al conjunto diagnóstico permanente	Media
5	Recolectar emojis de amenaza reales: la cobertura sigue siendo 100 % sintética	Media

8. Recomendación para la tesina

Qué modelo reportar

Reportar los dos, con papeles distintos, y no declarar cumplida la meta de 0.80.

1. **XLM-R v1 es el mejor clasificador del proyecto en la métrica principal.** F1-macro 0.8058, la mejor calibración (ECE 0.0871, menos de la mitad que mBERT) y el mejor desempeño en las dos clases críticas. Es la cifra de titular.
2. **Pero es frágil.** 0/12 en emojis de amenaza, 26/72 en amenazas ofuscadas, brecha dialectal de +0.50. Un F1 alto sobre un test que no contiene ofuscación no dice nada sobre cómo se comporta ante evasión deliberada, que es exactamente lo que hay en moderación real.
3. **mBERT B2 es el modelo robusto.** 167/204 en la sonda nueva contra 105 de XLM-R v1, 12/12 en emojis de amenaza, cero falsos negativos en amenazas ofuscadas, brecha dialectal invertida. Paga 0.0448 de F1-macro por ello.

El resultado defendible del proyecto es precisamente esa tensión, y es un resultado interesante: **el aumento sintético dirigido compra robustez ante evasión al precio de F1 sobre la distribución natural.** Está cuantificado en las dos direcciones y es reproducible. Vale más que un F1 alto sin análisis de robustez.

Qué cifras van al documento

Bloque	Cifra	Fuente
Métrica principal	XLM-R v1 0.8058 IC95 [0.7665, 0.8420] · mBERT B2 0.7610 IC95 [0.7172, 0.7983]	reejecución propia
Meta 0.80	No alcanzada con significancia. El IC de XLM-R incluye valores por debajo de 0.77	—
Comparativa	McNemar b = 26, c = 44, p = 0.0414, a favor de XLM-R	reejecución propia

Bloque	Cifra	Fuente
Robustez	Batería 144 (declarando el solape de 7) + sonda de 204 casos	reejecución propia
Fairness	FPR jerga 0.4138 / sin jerga 0.1596, declarando n = 29	reejecución propia
Pisos triviales	mayoritaria 0.1284 · azar 0.2451–0.2496	reejecución propia
Baselines	LinearSVC 0.7482 · LogReg 0.7354 · MNB 0.6932	reejecución propia

Qué no va

- **Ninguna cifra del Prototipo V2 en su forma actual.** No por rigor excesivo: por contaminación del test. Las tres cifras de resultado no se reproducen desde los pesos entregados y el modelo vio 21 textos del conjunto de prueba.
- **El 14.63 % de FPR.** Compara poblaciones distintas y está contaminado.
- **El conjunto N = 1050.** No existe.
- **El 120/144 sin declarar** que 7 de esos 144 están en el train y que la tabla mezcla dos baterías.
- **El capítulo de interpretabilidad** mientras las tres tablas digan «datos no disponibles».

Dónde encaja el trabajo de Julio

Como sección de **alternativas evaluadas y descartadas**, que es un aporte real si se presenta así. Su sección 4, el análisis crítico de las limitaciones de las heurísticas, está bien escrita y es honesta: anticipa el fallo de «gracias» antes de que nadie lo midiera. Esa sección más la medición de evadibilidad de 7.4.6 componen un argumento sólido a favor de resolver el sesgo con datos y no con reglas — que es justamente lo que la comparación con B2 demuestra. Presentado así, su trabajo sostiene la conclusión del capítulo en lugar de competir con ella.

Anexo. Artefactos generados

Todo en reports/v2_auditoria/:

Fichero	Contenido
manifiesto_pesos.json	SHA-256, arquitectura e id2label de los cuatro checkpoints
logits_<modelo>_<conjunto>.npz	Logits crudos: 4 modelos × {test, val, adv, sonda}
metricas_reproducidas.json	Métricas globales, por clase, matrices, cortes e IC
mcnemar.json	Las seis comparaciones pareadas y los Δ F1 con IC bootstrap
preds_<modelo>.csv	ID, y_pred sobre test, para comparación pareada
bateria_predicciones.csv	Batería entregada, 144 casos, predicción de cada modelo
bateria_cristian_predicciones.csv	Batería propia de Cristian, para el contraste de 3.2
sonda_predicciones.csv	Sonda dirigida, 204 casos, crudo y normalizado

Fichero	Contenido
evadibilidad_julio.csv	700 filas: 100 amenazas × 7 prefijos, salida de los tres niveles
pdf/*.txt	Texto extraído de los cinco PDF auditados

Scripts en src/audit/: reproducir_2v.py, metricas_2v.py, bateria_2v.py, pipeline_julio.py, sonda_ofuscacion_emoji.py. Todos deterministas con semilla 42.