

Análisis Exploratorio y Preparación de Datos

Corpus Salvadoreño de Toxicidad y Discurso de Odio

Universidad de El Salvador
Facultad de Ingeniería y Arquitectura
Escuela de Sistemas Informáticos

Julio Enrique De La Quadra Mata
Cristian Antonio Escalante Hernández
Willian Alexander Chávez Servellón

Etapa II — Preparación de Datos para *fine-tuning* de mBERT y XLM-R

30 de julio de 2026

Resumen ejecutivo

Este informe documenta la auditoría, las decisiones de limpieza y la construcción de los conjuntos de entrenamiento del corpus salvadoreño de toxicidad (3,104 publicaciones anotadas de X y Facebook). La tesis central es que el preprocesamiento clásico de PLN —minúsculas, eliminación de tildes, corrección ortográfica, *stopwords*, lematización— es **contraproducente** con modelos Transformer preentrenados, y se sustituye por un criterio de **preservación máxima** que normaliza únicamente lo que no es lingüístico. Se documentan además tres hallazgos que condicionan la fase de modelado: una divergencia de protocolo entre anotadores que produjo 16 etiquetas donde debían existir 4, un fallo de anonimización en la columna de procedencia, y la ausencia total de validación cruzada entre anotadores.

1. Alcance y principio rector

El objetivo del proyecto es clasificar automáticamente toxicidad y discurso de odio en publicaciones salvadoreñas de X y Facebook mediante *fine-tuning* de **mBERT** y **XLNet**, con meta de F1-macro superior al 80%. Este documento cubre la fase de *Preparación de los Datos* de CRISP-DM: qué contiene el corpus, qué problemas tiene, qué se corrige, qué se preserva deliberadamente, y por qué.

1.1 Por qué no se aplica el preprocesamiento clásico

La receta habitual de PLN —pasar a minúsculas, quitar tildes, corregir la ortografía, eliminar puntuación y *stopwords*, lematizar— se diseñó para modelos de bolsa de palabras (TF-IDF, SVM, Naive Bayes), donde cada término es una dimensión independiente y reducir la dispersión del vocabulario mejora el rendimiento. Con Transformers preentrenados el planteamiento se invierte, por tres razones:

- **Desalineación con el preentrenamiento.** mBERT y XLNet construyeron sus representaciones sobre español real, con tildes, mayúsculas y puntuación. El tokenizador *subword* ya modela esas formas. Eliminarlas empuja la entrada fuera de la distribución sobre la que el modelo aprendió.
- **La deformación ortográfica es señal, no ruido.** En contenido tóxico, escribir pvto o 4güevo suele ser evasión deliberada de filtros de moderación. Es exactamente el fenómeno que el sistema debe detectar. El léxico del proyecto documenta 2,035 de estas variantes precisamente porque importan.
- *Train/serve skew.* En producción la API recibirá texto crudo de usuarios. Toda transformación aplicada durante el entrenamiento debe replicarse de forma idéntica en inferencia; si no, el modelo funciona en el *notebook* y falla en la demo. Cuanto más corto y determinista el *pipeline*, menor el riesgo.

Decisión de arquitectura

Por esta última razón, la normalización no vive en el notebook sino en `src/features/normalization.py`. Ese módulo es la **única fuente de verdad**: lo importan el notebook de EDA, el script de entrenamiento y el *endpoint* de FastAPI. Es la garantía estructural contra el *train/serve skew*, no una preferencia de organización.

1.2 Qué sí se normaliza

Se normaliza aquello que **no transporta significado lingüístico** y aquello que identifica a personas:

Operación	Motivo
Unicode NFC	Dos representaciones binarias de «á» deben producir el mismo token.
Reparación de <i>mojibake</i> (ftfy)	Restaura la «ñ» y las vocales acentuadas cuando la codificación se corrompió al exportar.
Eliminar caracteres invisibles	Zero-width y marcas bidireccionales rompen los tokenizadores.
Colapsar espacios en blanco	El <i>whitespace</i> no es señal lingüística.
@menciones → @usuario	Anonimiza sin borrar la señal de «ataque dirigido».
URLs → http://url	Ídem; además la URL concreta no generaliza.
Emojis → descripción en español	Evita [UNK]; ver sección 5.

2. Hallazgo 1: divergencia de protocolo entre anotadores

La taxonomía del proyecto define **cuatro clases**. La columna *Clase_Toxicidad* del archivo contiene **dieciséis valores distintos**. La pregunta relevante no es cómo limpiarlo sino **por qué ocurrió**, porque la respuesta determina cuál es la corrección adecuada.




Figura 1. Izquierda: los 16 valores presentes en *Clase_Toxicidad*. Derecha: las etiquetas anómalas no se reparten entre el equipo, se concentran en un solo anotador.

Las 348 filas anómalas provienen **íntegramente de un solo anotador**, que registró el nivel de *subclase* en la columna de *clase*: anotó racismo, xenofobia, clasismo donde el protocolo pedía Discurso de Odio en la clase y el eje de discriminación en la subclase. A esto se suma una colisión de mayúsculas: Discurso de odio (672 filas, dos anotadores) frente a Discurso de Odio (12 filas, un anotador).

Diagnóstico

No es un error de tipeo, es una **divergencia de protocolo**. Tiene dos consecuencias operativas. Primera: la corrección no puede resolverse con un `.str.title()`; requiere un mapeo semántico explícito, documentado y auditable. Segunda, y más importante: revela que **la guía de anotación no fue suficientemente unívoca**. Debe corregirse antes de la ronda de validación cruzada, o el coeficiente Kappa medirá confusión sobre las reglas en lugar de desacuerdo genuino de criterio.

2.1 Criterio de consolidación

La clase se define por el objeto del ataque, no por su eje. Un ataque a un grupo protegido es *Discurso de Odio*, sea el eje racial, nacional, religioso, corporal o socioeconómico. El eje se preserva en *Subclase_Toxicidad*, que es donde pertenece taxonómicamente.

Etiqueta cruda	n	Clase canónica asignada
discriminacion (gordofobia, homofobia, capacitismo, misoginia, serofobia, edadismo)	104	Discurso de Odio
racismo	63	Discurso de Odio
xenofobia	63	Discurso de Odio
clasismo	55	Discurso de Odio
religiofobia	27	Discurso de Odio
antisemitismo	12	Discurso de Odio
Discurso de Odio (colisión de mayúsculas)	12	Discurso de Odio
Insulto (sin grupo protegido: descalificación política, deportiva)	17	Lenguaje Ofensivo

Cuatro etiquetas no se resuelven automáticamente. Se apartan para revisión humana en lugar de asignarles una clase por defecto: son **7 filas**, el coste de revisarlas a mano es trivial y el de introducir ruido en una clase minoritaria no lo es.

Apartada	n	Motivo de la ambigüedad
discriminacion_politica	3	La afiliación política no es categoría protegida en la mayoría de taxonomías de <i>hate speech</i> .
violencia_psicologica	2	El término no existe en la taxonomía del proyecto.
incitacion_odio	1	Frontera entre <i>Discurso de Odio</i> y <i>Amenazas/Violencia</i> .
violencia_genero	1	¿Ataque a las mujeres como grupo o amenaza a una persona concreta?

3. Hallazgo 2: la anonimización estaba anulada

El corpus es candidato a publicarse en un repositorio de GitHub público, requisito explícito de la rúbrica de la Etapa II. Se auditaron tres superficies de exposición: menciones dentro del texto, URLs dentro del texto y la columna de procedencia.

Superficie auditada	Filas	%
@menciones dentro del texto	147	4.74
URLs dentro del texto	54	1.74
Hashtags	293	9.44
Correos electrónicos	0	0.00
Posibles números telefónicos (formato SV)	0	0.00
URL_Original con <i>handle</i> real de la cuenta	1,542	49.68

La columna `Usuario_ID_Anonimizado` contiene seudónimos correctos (`USER_001`, ...). Pero la columna `URL_Original` conserva la dirección real de cada publicación, y en X el *handle* de la cuenta forma parte de la propia ruta:

```
https://x.com/<handle>/status/<id>
```

Riesgo ético y legal

La seudonimización queda **completamente anulada**: cualquiera que abra la URL obtiene la identidad del autor. Publicar el CSV en ese estado equivale a publicar los usuarios sin anonimizar, con el agravante de que el contenido está etiquetado como tóxico —lo que convierte el dataset en una lista nominal de personas señaladas. Afecta a la mitad del corpus.

3.1 Corrección adoptada

Artefacto	Contenido	Destino
<code>data/processed/*.csv</code>	Texto normalizado, etiquetas, seudónimo y un hash SHA-256 truncado del origen. Sin URL.	Repositorio público
<code>data/interim/mapa_procedencia.csv</code>	Correspondencia ID → URL real, para reverificar anotaciones.	Local. Excluido en <code>.gitignore</code> .

El hash permite detectar duplicados entre *splits* y auditar la procedencia sin revelarla. Se conserva la trazabilidad interna que el equipo necesita, y se elimina la exposición pública.

3.2 Menciones: se reemplazan, no se eliminan

Las @menciones dentro del texto se sustituyen por el token constante `@usuario`. La distinción con eliminarlas es deliberada: la **presencia** de una mención distingue un ataque dirigido a una persona concreta de una afirmación general, y esa diferencia es señal predictiva legítima para la clasificación. Se borra la identidad y se conserva la estructura sintáctica. El mismo criterio se aplica a las URLs.

4. Hallazgo 3: no existe validación entre anotadores

El perfil de trabajo del proyecto fija **Cohen's Kappa ≥ 0.60** como umbral de calidad del etiquetado. El estado real del corpus es el siguiente:

Columna	Valores no nulos	Estado
Validado	3,104	Rellena, pero con «NO» en todas las filas
Validador	0	Vacía
Fecha_Validacion	0	Vacía
Cohen_Kappa	0	Vacía
Acuerdo_Validador	0	Vacía

Brecha metodológica

Ninguna de las 3,104 filas ha pasado por doble anotación. Sin acuerdo inter-anotador medido no hay evidencia de que las etiquetas sean reproducibles, y por tanto ningún resultado de F1 posterior es interpretable: no se sabe si el techo de rendimiento del modelo lo impone el modelo o el ruido de las etiquetas. Es la brecha metodológica más seria del dataset y un jurado la señalará.

4.1 Protocolo propuesto

El notebook genera `plantilla_doble_anotacion.csv`: una muestra estratificada por clase y plataforma del 15% del corpus (460 ítems), con el segundo anotador ya asignado de forma que nunca coincida con el original y el orden aleatorizado. Pasos:

- **Unificar primero la guía de anotación.** La divergencia de la sección 2 es de protocolo; medir Kappa antes de resolverla mediría confusión sobre las reglas.
- El segundo anotador etiqueta **a ciegas**: la columna con la etiqueta original debe ocultarse antes de repartir el archivo.
- Calcular Kappa **global y por clase**. Un valor global aceptable puede ocultar uno pésimo en *Amenazas/Violencia*, que es la clase crítica del sistema.
- Resolver los desacuerdos por **adjudicación de un tercero**, nunca promediando.
- Reportar el valor en el documento final. Si $Kappa < 0.60$, refinar la guía y repetir sobre una muestra nueva.

Qué esperar. En detección de discurso de odio, la literatura reporta habitualmente Kappa entre 0.45 y 0.70; HatEval se sitúa en ese rango. Los focos sistemáticos de desacuerdo son el sarcasmo y la ironía — y este corpus tiene columnas específicas para ambos, lo que permite cuantificar el efecto y aprovecharlo en el análisis de errores de la Etapa II.

5. Emojis: la decisión con mayor impacto técnico

Los emojis son la pregunta más interesante del preprocesamiento, porque transportan significado real y los tokenizadores los tratan mal. La primera cuestión es empírica: ¿son relevantes en este corpus?




Figura 2. Izquierda: emojis más frecuentes. Derecha: la presencia de emoji no se distribuye al azar entre clases.

La respuesta es sí. Solo el 6.3% de los textos contiene emojis, pero **no se reparten al azar**: aparecen en el 18.4% de *Lenguaje Ofensivo* y en el 0.4% de *No Tóxico*. Los más frecuentes son marcadores de burla, desprecio y agresión — caras de risa, heces, dedo corazón, payaso, cara enfadada. Es decir: el emoji es una **variable predictiva**, no un adorno. Descartarlos es descartar señal.

A esto se añade el catálogo propio del proyecto (`lexicon_emojis.csv`), que documenta casos en los que el emoji **es** el vehículo del odio: el mono junto a una bandera nacional como bestialización racial, o el jabón junto a la bandera de Israel como referencia al Holocausto. En esos casos el texto circundante puede ser perfectamente inocuo.

5.1 Qué hace cada modelo con un emoji

	mBERT (bert-base-multilingual-cased)	XLM-R (xlm-roberta-base)
Tokenizador	WordPiece, vocabulario ~119k	SentencePiece/BPE, vocabulario ~250k
Corpus del vocabulario	Volcados de Wikipedia (2018)	CommonCrawl / CC-100 (~2 TB de web)
Presencia de emojis ahí	Prácticamente nula	Sí: es texto web real
Resultado esperado	La mayoría cae en [UNK]: señal perdida	Los comunes se cubren; secuencias ZWJ, banderas y tonos de piel se fragmentan

Wikipedia no usa emojis; CommonCrawl sí. De ahí la asimetría. Y un [UNK] no es un token neutro: colapsa la cara de risa, las heces y el dedo corazón en el **mismo vector**, borrando toda distinción entre burla, desprecio y agresión. Peor aún, la comparación mBERT contra XLM-R quedaría contaminada por una diferencia de cobertura de vocabulario en lugar de medir capacidad de clasificación.

5.2 Decisión: demojizar a español

"sos un [payaso]" → "sos un :cara_de_payaso:"
 "te voy a [dedo]" → "te voy a :dedo_corazón_hacia_arriba:"

- **Iguala el terreno entre modelos.** La descripción textual se segmenta en *subwords* que ambos modelos conocen. La comparación pasa a medir lo que queremos medir.
- **Aprovecha el preentrenamiento en español.** El modelo ya tiene representación semántica de «payaso», «caca», «dedo». El emoji crudo no activa nada equivalente.
- **Consistencia con el baseline.** RoBERTuito (*pysentimiento*), uno de los baselines del proyecto, aplica esta misma conversión en su preprocesamiento. Sin ella la comparación contra el baseline sería injusta.
- **Es reversible.** Nada se destruye: el texto original permanece intacto en el dataset como columna separada.

Modificadores de tono de piel. Se eliminan. El dedo corazón claro y el oscuro expresan lo mismo; el modificador Fitzpatrick solo fragmenta el token y dispersa la señal entre variantes que deberían compartir representación.

Verificación pendiente

Esta decisión es una **hipótesis fundamentada, no un resultado**. Por eso el dataset se exporta con tres variantes de texto en paralelo — original, demojizado y agresivamente normalizado — de modo que en la Etapa II se pueda medir el F1 de cada una en ambos modelos y reportar la diferencia con evidencia. Ese cuadro de cuatro celdas es lo que convierte una decisión de preprocesamiento en un aporte del trabajo, defendible ante un jurado.

6. Tildes, espacios y faltas de ortografía

Las observaciones recibidas sobre limpieza superficial se responden aquí con medición, no con opinión.

Indicador	n	% del corpus
Textos con tildes o ñ	1,825	58.79
Espacios sobrantes al inicio o final	0	0.00
Espacios dobles internos	0	0.00
Saltos de línea	0	0.00
Difieren de su forma Unicode NFC	0	0.00
Mojibake detectado	0	0.00
Fechas fuera del formato ISO	1	0.03
Textos duplicados (tras normalizar)	72	2.32

6.1 Sobre los espacios

El corpus **ya está limpio en la capa superficial**: cero espacios sobrantes, cero espacios dobles, cero saltos de línea, cero desviaciones de NFC, cero *mojibake*. Los pasos de recorte y colapso de espacios se mantienen en el *pipeline* —son baratos y protegen frente a la entrada de producción,

que sí vendrá sucia— pero sobre este corpus no modifican una sola fila. La discusión relevante no está ahí.

6.2 Sobre las tildes

El 59% de los textos llevan tilde o ñ. Eliminarlas sería el error más costoso del preprocesamiento clásico:

- En español la tilde es **distintiva**, no ornamental: «él» / «el», «sí» / «si», «papá» / «papa», «esta» / «está». Quitarla introduce ambigüedad léxica real.
- XLM-R conserva las tildes siempre.
- mBERT las conserva **solo en la variante *cased***. La variante *uncased* aplica `strip_accents=True` y las destruye silenciosamente dentro del propio tokenizador.
- Quitarlas fuerza al tokenizador a fragmentar palabras que conocía enteras, alargando la secuencia y degradando la representación.

Punto crítico de configuración

Requisito operativo para la Etapa II: usar `bert-base-multilingual-cased`, nunca la variante *uncased*. Sería posible tomar todas las decisiones correctas en el preprocesamiento y perderlas dentro del tokenizador sin ningún aviso.

6.3 Sobre corregir la ortografía

No se corrige. La objeción intuitiva es «el modelo no conocerá esa palabra mal escrita», pero no aplica a Transformers: los tokenizadores *subword* descomponen cualquier cadena en piezas conocidas. 4güevo no produce un [UNK]; produce una secuencia de *subwords*, y con suficientes ejemplos el modelo aprende a asociarla con su clase.

El argumento decisivo, sin embargo, es operativo: en producción la API recibirá texto con esas mismas faltas. Un modelo entrenado sobre texto corregido y evaluado sobre texto real sufre *train/serve skew*. Y en contenido tóxico la deformación es con frecuencia **evasión intencional de moderación**: es el fenómeno que hay que detectar, no ruido que haya que eliminar.




Figura 3. Perfil lingüístico: distribución de longitud por clase, contraste entre plataformas y composición de clases en X frente a Facebook.

7. Implicaciones para el fine-tuning

7.1 Balance de clases




Figura 4. Distribución tras consolidar a cuatro clases, contrastada con los umbrales del dimensionamiento estadístico del proyecto.

Tras la consolidación el corpus alcanza 3,057 filas útiles. El total supera el escenario de alta precisión del dimensionamiento (3,084), pero **la cobertura por clase no es uniforme**: el ratio entre la clase mayoritaria y la minoritaria es de 2.1 a 1, y *Amenazas/Violencia* (501) queda apenas por encima del umbral mínimo de 480 mientras *Lenguaje Ofensivo* (1,036) lo duplica.

Un modelo entrenado sin corrección tenderá a predecir la clase mayoritaria, y el F1-macro —que promedia las clases sin ponderar por frecuencia— caerá arrastrado por la clase minoritaria. Mitigaciones, en orden de preferencia:

- **Ponderación en la función de pérdida.** Sin coste de datos, primera opción. Los pesos ya están calculados sobre *train* y guardados en *metadata.json*.
- **Recolección dirigida de Amenazas/Violencia.** Es la solución real, no un parche.
- *Data augmentation* aprovechando las variantes del léxico salvadoreño.
- *Oversampling*: última opción. Con Transformers y textos cortos favorece el sobreajuste por memorización.

Regla metodológica

Cualquier remuestreo o ponderación se calcula y aplica **únicamente sobre train**. Hacerlo antes del *split* filtra información del conjunto de prueba y produce métricas infladas que no se sostienen en la defensa.

Clase	n	Peso para la pérdida
No Tóxico	537	1.4222
Lenguaje Ofensivo	1,036	0.7376
Discurso de Odio	983	0.7773
Amenazas/Violencia	501	1.5279

7.2 Longitud de secuencia

La longitud estimada de las secuencias sitúa el percentil 99 alrededor de 126 tokens y solo el 1% del corpus por encima de 128. El criterio es cubrir el percentil 95-99 sin pagar *padding* innecesario:

- **max_length = 128** como configuración base. Cubre prácticamente todo el corpus.
- **max_length = 256** solo si el análisis empírico muestra truncamiento significativo en los comentarios largos de Facebook.
- Usar 512 desperdiciaría cómputo: la atención escala de forma cuadrática, y pasar de 128 a 512 multiplica por unas 16 veces el coste de esa capa sin ganancia.
- *Padding dinámico por lote* en lugar de longitud fija: reduce el cómputo real sin afectar el resultado.

7.3 Predicción sobre mBERT frente a XLM-R

	mBERT	XLM-R
Vocabulario	~119k WordPiece	~250k SentencePiece
Preentrenamiento	Wikipedia, 104 idiomas	CommonCrawl, 100 idiomas, ~2 TB
Registro coloquial	Escaso: Wikipedia es formal	Abundante: la web sí lo tiene
Tildes	Solo la variante <i>cased</i>	Siempre
Cobertura de emojis	Casi nula	Parcial
Tokens por texto en español	Más (vocabulario menor)	Menos

Hipótesis del proyecto: XLM-R debería superar a mBERT en este corpus, porque el registro que lo caracteriza —jerga salvadoreña, coloquialismos, deformación ortográfica deliberada— está mucho mejor representado en CommonCrawl que en Wikipedia. El estudio de ablación de la Etapa II debe confirmarlo o refutarlo. Si lo refuta, eso también es un resultado, y uno interesante.

8. Resumen de decisiones

Aspecto	Decisión	Justificación
Tildes y ñ	Se conservan	Distintivas en español; mBERT- <i>cased</i> y XLM-R las modelan
Mayúsculas	Se conservan	Señal de énfasis y agresión; los modelos son <i>cased</i>

Aspecto	Decisión	Justificación
Ortografía	No se corrige	Es señal (evasión de moderación) y evita <i>train/serve skew</i>
Puntuación	Se conserva	Los tokenizadores <i>subword</i> la aprovechan
Stopwords, lematización	No se aplican	Receta de bolsa de palabras; destruyen la sintaxis que usa la atención
Espacios, Unicode NFC	Se normalizan	No lingüístico; protege frente a la entrada de producción
Emojis	Demojizar a español	Evita [UNK] en mBERT; iguala la comparación; consistente con RoBERTuito
Tono de piel	Se elimina	Variantes equivalentes; solo dispersan la señal
@menciones y URLs	Token constante	Anonimiza preservando la señal de ataque dirigido
URL_Original	Fuera del dataset público	Contiene el <i>handle</i> real: anula la seudonimización
Etiquetas	16 → 4, mapeo documentado	Divergencia de protocolo, no error de tipeo
Casos ambiguos	Revisión humana	7 filas; no contaminar clases minoritarias
Desbalance	Ponderación en la pérdida	Sin coste de datos; remuestreo solo sobre <i>train</i>
max_length	128	Cubre el percentil 99; la atención escala de forma cuadrática

9. Artefactos generados




Figura 5. Retención de filas a lo largo del pipeline y composición estratificada de los conjuntos resultantes.

Ruta	Contenido
notebooks/01_eda_y_limpieza.ipynb	Análisis reproducible completo, ejecutado
src/features/normalization.py	Pipeline de normalización. Fuente única de verdad.
src/data/label_mapping.py	Mapeo 16 → 4 documentado y auditable

Ruta	Contenido
data/processed/train / val / test.csv	2,139 / 459 / 459 filas, estratificados, sin solapamiento
data/processed/corpus_limpio.csv	3,057 filas, tres variantes de texto
data/processed/metadata.json	Semilla, pesos de clase, configuración y pendientes
data/interim/cola_revision_etiquetas.csv	7 filas a resolver manualmente
data/interim/plantilla_doble_annotacion.csv	460 ítems para la ronda de Kappa
data/interim/mapa_procedencia.csv	ID → URL real. No versionar.

Los *splits* se generaron con semilla fija (42) y se verificó ausencia total de solapamiento de identificadores entre conjuntos. La comprobación de fuga por autor resultó innecesaria: ningún usuario aparece más de una vez en el corpus, de modo que no hay riesgo de que el modelo memorice el estilo de un autor presente simultáneamente en entrenamiento y prueba.

10. Trabajo pendiente antes de entrenar

#	Tarea	Prioridad
1	Unificar la guía de anotación y resolver las 7 filas apartadas	Alta
2	Ejecutar la ronda de doble anotación y reportar Cohen's Kappa	Crítica
3	Recolección dirigida de <i>Amenazas/Violencia</i> hasta superar holgadamente 480	Alta
4	Retirar URL_Original de cualquier publicación del dataset	Crítica
5	Reparar la codificación y la cabecera de lexicon_emojis.csv	Media
6	Descargar los datasets públicos a data/external/ para la primera etapa de <i>fine-tuning</i>	Alta
7	Ejecutar el notebook en Colab para obtener las cifras reales de tokenización	Media

Enlace con la fase de modelado

El dataset se exporta con tres variantes de texto — `texto_modelo` (producción), `texto_agresivo` (control) y `texto_original` (trazabilidad) — precisamente para que el estudio de ablación de la Etapa II pueda reportar el F1-macro de cada variante en mBERT y en XLM-R. Ese resultado convierte «decidimos no quitar las tildes» en evidencia experimental, que es lo que sostiene la decisión frente a un jurado.