

Verificación independiente de los modelos entregados

mBERT y XLM-RoBERTa · reejecución de métricas y pruebas de robustez

Campo	Contenido
Objeto	Modelos entregados por Cristian Escalante (mBERT) y Julio De La Quadra (XLM-R)
Método	Reejecución completa del paso hacia adelante sobre los pesos entregados
Conjuntos	test.csv (n = 460) y batería adversarial (n = 144)
Autor	Willian Alexander Chávez Servellón
Fecha	1 de septiembre de 2026

Índice

1. Qué se hizo y por qué

Hasta ahora los informes de métricas se venían aceptando tal como llegaban. Esta verificación no repite los números publicados: **vuelve a ejecutar los modelos** sobre los pesos entregados y contrasta el resultado con lo que cada informe afirma.

El entorno de trabajo no admite PyTorch, así que el paso hacia adelante de ambas arquitecturas se reimplementó en NumPy leyendo `model.safetensors` directamente. Esa reimplementación se validó de dos formas independientes antes de usarla para juzgar nada:

- mBERT reproduce **exactamente** su F1-macro oficial de 0.7777 y su accuracy de 0.7826.
- XLM-R coincide al **100 % (460 de 460 predicciones)** con el archivo de predicciones exportado de forma independiente en el repositorio de mBERT.

Con eso descartado, cualquier diferencia frente a los informes es atribuible a los informes, no al método de verificación.

2. Resumen de hallazgos

#	Hallazgo	Modelo	Severidad
1	El informe nuevo de XLM-R publica F1-macro 0.8100 y accuracy 0.8109; los valores reales son 0.8058 y 0.8065	XLM-R	Alta
2	La matriz de confusión del informe de XLM-R contradice su propia tabla por clase	XLM-R	Alta
3	El config.json entregado sigue con LABEL_0 a LABEL_3 pese a declarar la corrección completada	XLM-R	Media
4	El segundo informe de mBERT describe una corrida distinta a los pesos entregados	mBERT	Alta
5	El baseline trivial sigue publicado como 0.087; el correcto es 0.1284	mBERT	Media
6	El capítulo de interpretabilidad no tiene contenido (Jaccard LIME-SHAP = 0 en todas las instancias)	mBERT	Media
7	Ningún modelo fue reentrenado con el dataset B2	Ambos	Alta
8	Ninguna diferencia entre modelos es estadísticamente concluyente	Ambos	Informativo

3. Métricas reejecutadas sobre test.csv

3.1 Globales

Métrica	mBERT	XLM-R
F1-macro	0.7777	0.8058
Accuracy	0.7826	0.8065
Aciertos	360 de 460	371 de 460

Contraste con lo publicado. mBERT cuadra al cuarto decimal con su paquete de auditoría. XLM-R no: su informe publica 0.8100 y 0.8109.

Cifra	Publicado	Verificado	Diferencia
mBERT — F1-macro	0.7777	0.7777	—
XLm-R — F1-macro	0.8100	0.8058	-0.0042
XLm-R — accuracy	0.8109	0.8065	-0.0044 (2 ejemplos)

3.2 Por clase

Clase	P mBERT	R mBERT	F1 mBERT	P XLm-R	R XLm-R	F1 XLm-R	Sop.
No Tóxico	0.8496	0.7805	0.8136	0.8636	0.7724	0.8155	123
Lenguaje Ofensivo	0.7738	0.8176	0.7951	0.7778	0.8365	0.8061	159
Discurso de Odio	0.7347	0.7579	0.7461	0.7879	0.8211	0.8041	95
Amenazas/Violencia	0.7654	0.7470	0.7561	0.8125	0.7831	0.7975	83

La tabla por clase del informe de XLm-R es **correcta**: No Tóxico y Discurso de Odio coinciden al cuarto decimal. El problema está en la matriz de confusión y en las cifras globales.

3.3 La contradicción interna del informe de XLm-R

No hace falta acceder a las predicciones para detectarla. Basta despejar la columna de la matriz a partir de la tabla por clase publicada: si el recall y el soporte dan los verdaderos positivos, y la precisión es TP entre el total de la columna, la columna queda determinada.

Clase	TP = R × soporte	Columna implícita = TP / P	Columna en su matriz	Cuadra
No Tóxico	95.0	110.0	110	Sí
Lenguaje Ofensivo	134.0	171.3	171	Sí
Discurso de Odio	78.0	99.0	106	No
Amenazas/Violencia	64.2	79.5	73	No

Además, la diagonal de esa matriz suma **371** aciertos, que dan accuracy 0.8065, no el 0.8109 que publica en la misma página. La matriz proviene de otra corrida o fue transcrita a mano. La real es esta:

Real \ Predicho	No Tóxico	Ofensivo	Odio	Amenazas
No Tóxico	95	16	7	5
Lenguaje Ofensivo	9	133	8	9
Discurso de Odio	5	11	78	1
Amenazas/Violencia	1	11	6	65

3.4 Cortes y sesgo dialectal

Estos sí están bien en el informe de XLM-R. Las cifras de plataforma y de FPR por jerga se reprodujeron sin discrepancia, lo que confirma que el des-hardcodeo del FPR se hizo correctamente.

Corte	n	mBERT	XLM-R	Julio publica
Plataforma X	228	0.8386	0.8673	0.8670 ok
Plataforma Facebook	232	0.6727	0.7154	0.7150 ok
FPR No Tóxico, sin jerga	94	0.1596	0.1596	15.96 % ok
FPR No Tóxico, con jerga	29	0.4138	0.4483	44.83 % ok

La brecha dialectal es real en los dos modelos: una frase inofensiva con jerga salvadoreña tiene entre 2,6 y 2,8 veces más probabilidad de ser marcada como tóxica que su equivalente en español estándar.

4. Pruebas de robustez: batería de 144 casos

Es la primera vez que la batería completa se corre sobre **ambos** modelos. Ninguno de los dos informes la reporta.

Grupo de prueba	n	mBERT	XLNet	Qué mide
A. Ofuscación de groserías	20	18 (90 %)	17 (85 %)	p*ta, put@s, m13rda
B. Emojis	18	7 (39 %)	6 (33 %)	Emojis del catálogo
C. Amenazas ofuscadas	11	6 (55 %)	5 (45 %)	m4t4r, dar piso
D. Jerga salvadoreña inofensiva	14	2 (14 %)	8 (57 %)	pajero, cerote, bicho
E. Control sin jerga	12	12 (100 %)	12 (100 %)	Español estándar
F. Falsos amigos dialectales	34	17 (50 %)	14 (41 %)	Jerga y contrastes
G. Pares mínimos de emoji	35	12 (34 %)	12 (34 %)	Mismo texto, distinto emoji
GLOBAL	144	74 (51 %)	74 (51 %)	

Empatan en 74 de 144, pero **fallan en cosas distintas**: mBERT es mejor en ofuscación de groserías y peor en jerga salvadoreña; XLNet al revés.

4.1 El atajo del emoji

Este es el hallazgo más contundente. Los pares mínimos aíslan el aporte del emoji: mismo texto, solo cambia el símbolo.

Observación	mBERT	XLNet
Un emoji inocuo vuelve tóxico un texto que el modelo veía como No Tóxico	7 de 8 (88 %)	6 de 8 (75 %)
Un emoji de ataque no cambia nada	5 de 15 (33 %)	6 de 15 (40 %)
De todas las variantes con emoji, cuántas se predicen Ofensivo	78 %	70 %

Está exactamente al revés de lo que debería. Los emojis que no significan agresión son los que disparan la toxicidad, y los que sí la señalan pasan desapercibidos. Ejemplos reales de esta corrida:

Texto	Esperado	mBERT	XLNet
Qué bonita familia ♥ (corazón)	No Tóxico	Ofensivo	No Tóxico
Ese es el vecino nuevo 👋 (saludo)	No Tóxico	Ofensivo	Ofensivo
Ahí viene el grupo de siempre 🙌 (manos en alto)	No Tóxico	Ofensivo	Ofensivo
Ya sabés lo que te espera 🍰 (pastel)	No Tóxico	Ofensivo	Ofensivo
Los que vienen del sur ⚽ (balón)	No Tóxico	Ofensivo	Ofensivo

Texto	Esperado	mBERT	XLNet
Ya sabés lo que te espera 🔫 (pistola)	Amenazas/Violencia	Ofensivo	Ofensivo
Te voy a buscar mañana 🔪 (cuchillo)	Amenazas/Violencia	Ofensivo	Ofensivo
Te espero afuera ☹️ (ataúd)	Amenazas/Violencia	Ofensivo	No Tóxico

La causa está documentada desde el EDA: el **89 %** de los textos con emoji del corpus v1 pertenecen a la clase Lenguaje Ofensivo. Los modelos no aprendieron qué significa cada emoji; aprendieron que si hay emoji, es ofensivo.

4.2 Amenazas no detectadas

Modelo	Amenazas perdidas	A qué clase las manda
mBERT	15 de 22 (68 %)	14 a Lenguaje Ofensivo, 1 a No Tóxico
XLNet	17 de 22 (77 %)	12 a Lenguaje Ofensivo, 5 a No Tóxico

XLNet es el más peligroso de los dos en este eje: manda **cinco amenazas a No Tóxico**, entre ellas «Te voy a dar piso», «Te espero afuera ☹️» y «Te voy a buscar mañana 🔪». Un falso negativo hacia Ofensivo al menos deja el contenido marcado; hacia No Tóxico lo deja pasar entero.

4.3 Vocabulario salvadoreño

Medición	mBERT	XLNet
Frases inofensivas con jerga clasificadas correctamente	15 de 44	18 de 44
Frases inofensivas con jerga marcadas como tóxicas	66 %	59 %
Control equivalente en español estándar	100 %	100 %

El contraste con el grupo de control es la prueba: el mismo contenido, sin jerga, se clasifica perfecto. Casos como «Ese majo es bien pajero, nunca cumple» (pajero = mentiroso), «El chucho de la vecina ladra toda la noche» (chucho = perro) o «Prestame pisto para el pasaje» (pisto = dinero) salen marcados como ofensivos.

5. Comparativa estadística entre modelos

Con las predicciones de ambos modelos sobre los mismos 460 ejemplos se puede hacer la prueba pareada, que es lo que exige comparar dos clasificadores sobre el mismo conjunto.

Prueba	Resultado	Lectura
F1-macro	XLm-R 0.8058 vs mBERT 0.7777 (delta = +0.0281)	XLm-R va adelante en el punto estimado
McNemar exacto	25 aciertos solo de mBERT, 36 solo de XLm-R; p = 0.20	No se rechaza la hipótesis nula
IC 95 % bootstrap del delta	[-0.0068 , +0.0627]	Incluye el cero

Conclusión: empate estadístico. XLm-R no es significativamente superior a mBERT. Y según el McNemar del propio informe de mBERT, mBERT tampoco supera de forma concluyente a un TF-IDF con LinearSVC (p = 0.31).

Con n = 460 el test no tiene resolución para separar diferencias de esta magnitud. Con la tasa de discordancia observada (13,3 %) haría falta un conjunto de prueba de aproximadamente **1.800 ejemplos**, casi cuatro veces el actual, para detectar un delta de 0.028 con 80 % de potencia.

Esto no es un resultado negativo: es un resultado válido y defendible. Lo que no es defendible es presentar «XLm-R gana» como si estuviera demostrado.

6. Estado de las correcciones pedidas

6.1 Julio, XLm-RoBERTa

Seis de siete correcciones se verificaron en el código, no solo en su declaración.

#	Corrección	Estado	Evidencia
1	FPR por jerga recalculado	Hecho	Calculado desde y_true e y_pred; lanza KeyError si falta n_jerga
2	Presencia_Sarcasmo e Ironia con SI y SÍ	Hecho	Con retrocompatibilidad a los nombres viejos
3	Métricas por plataforma	Hecho	Calculadas dinámicamente; 0.867 y 0.715 verificados
4	max_length = 128 unificado	Hecho	En tokenización e inferencia
5	Bootstrap, matriz numérica, 4 decimales	Hecho	B = 2000, percentil, semilla 42
6	id2label con nombres reales	NO	El config.json entregado sigue con LABEL_0 a LABEL_3
7	venv y pesos fuera del control de	Hecho	.gitignore correcto

#	Corrección	Estado	Evidencia
	versiones		

Pendiente para Julio: corregir el F1 y la accuracy globales del informe a 0.8058 y 0.8065, regenerar la matriz de confusión desde las predicciones reales, guardar el modelo con el id2label correcto y exportar preds_xlmr.csv con las columnas ID e y_pred.

6.2 Cristian, mBERT

El paquete de auditoría entregado es sólido: MANIFEST con commit, semilla y SHA-256 por archivo, contrato de inferencia, predicciones exportadas, registro de trazabilidad del F1 y el experimento B2 documentado. Es el trabajo más riguroso de los dos.

El problema es que entregó dos informes que describen dos modelos distintos.

	Informe 1	Informe 2 (nuevo)	Pesos entregados
Corrida	CPU, época 4	Colab GPU, época 5	época 4, ckpt-1072
F1-macro test	0.778	0.786	0.7777
F1-macro validación	0.771	0.756	0.7715
ECE	0.157	0.124	0.157

El informe 1 cuadra exactamente con los pesos. El informe 2 no: describe una corrida cuyos pesos no se entregaron. Y por el criterio de selección de checkpoint, que es el mejor F1 de **validación**, el modelo del informe 2 es el peor de los dos (0.756 frente a 0.7715). Elegirlo porque da mejor test es seleccionar sobre el conjunto de prueba, y además la diferencia cae dentro del intervalo bootstrap: es ruido.

Pendiente para Cristian: publicar el 0.7777 como cifra oficial, tal como ya dice su propio registro de trazabilidad; corregir el baseline trivial de 0.087 a 0.1284 (su archivo trivial_baselines.csv ya lo tiene bien, el informe quedó desincronizado); y resolver o retirar el capítulo de interpretabilidad, donde el Jaccard LIME-SHAP es 0 en todas las instancias y las tablas salen vacías.

7. Lo que sigue

Ninguno de los dos modelos entregados fue entrenado con el dataset B2: los dos train.csv tienen 2.144 filas y no traen las columnas origen ni plantilla_id.

Cristian sí corrió el experimento B2 y lo documentó. El resultado fue un intercambio real: la robustez mejoró mucho (amenazas no detectadas de 10 a 0, brecha de FPR dialectal de 0.857 a 0.286, emojis de 7 de 18 a 15 de 18) a costa de 6 puntos de F1-macro en el test. Lo rechazó por su regla de que si el F1 cae más de 0.02 no se adopta.

El diagnóstico de por qué cayó está en las predicciones: el modelo B2 pasó de 8 a 28 predicciones severas sobre los 75 casos y empezó a leer insultos como amenazas. La causa es la proporción: se añadieron 268 ejemplos sintéticos de Amenazas sobre una clase que tenía 389 reales, un aumento del 69 % con textos léxicamente muy marcados.

Acción	Responsable	Estado
Rebalancear B2 hacia B3: bajar los sintéticos de Amenazas de 268 a unos 90	Willian	Propuesto
Quitar las 7 filas de train que solapan con la batería adversarial	Willian	Confirmado
Reentrenar con B3 y correr la batería de 144 casos	Julio y Cristian	Pendiente
Corregir los informes según la sección 6	Julio y Cristian	Pendiente
Ampliar el conjunto de prueba hacia unos 1.800 ejemplos	Equipo	Pendiente

Regla que no se puede romper: los dos reentrenamientos deben usar el mismo dataset y los mismos pesos de clase. Si uno entrena con B3 y el otro con v1, la comparación entre modelos deja de tener sentido.

Anexo. Reproducibilidad

Archivo	Contenido
src/audit/mbert_numpy.py	Paso hacia adelante de mBERT en NumPy
src/audit/xlmr_numpy.py	Paso hacia adelante de XLM-RoBERTa en NumPy
reports/verificacion/preds_mbert.csv	Predicciones de mBERT sobre test.csv (ID, y_pred)
reports/verificacion/preds_xlmr.csv	Predicciones de XLM-R sobre test.csv (ID, y_pred)
reports/verificacion/adversarial_144.csv	Los 144 casos con predicción y confianza de ambos modelos
reports/verificacion/resumen_grupos.csv	Aciertos por grupo de prueba

Todas las cifras de este informe provienen de esas ejecuciones. Ninguna se copió de los informes revisados.